

Análise Multivariada

Wine Quality

Vinhos Verdes Portugueses — UCI Machine Learning Repository

Cortez et al. (2009) — Universidade do Minho, Portugal

Disciplina: Análise Multivariada

Aluno: Gabriel Pereira

Data: Setembro de 2026

1. Descrição da Base de Dados

A base de dados utilizada neste trabalho é a **Wine Quality**, disponível no UCI Machine Learning Repository (Cortez et al., 2009). Os dados foram coletados pelo Laboratório de Sistemas de Decisão e Inteligência Artificial (GECAD) da Universidade do Minho, em parceria com a Comissão de Viticultura da Região dos Vinhos Verdes (CVRVV) de Portugal.

A base compreende amostras de dois tipos de vinho da região dos Vinhos Verdes: **vinho tinto** (1.599 amostras) e **vinho branco** (4.898 amostras), totalizando **6.497 observações**. Para cada amostra foram registradas 11 variáveis físico-químicas contínuas obtidas em análise laboratorial, além de uma avaliação sensorial de qualidade (nota de 0 a 10) atribuída por especialistas certificados da CVRVV.

O maior número de vinhos brancos reflete a realidade da produção regional: o Vinho Verde branco domina a certificação e exportação da denominação de origem, sendo historicamente mais representativo no volume certificado pelo CVRVV.

Variáveis da Base


As 11 variáveis preditoras e a variável-resposta são descritas a seguir:

- **Fixed Acidity** — acidez fixa (ácido tartárico, g/dm³)
- **Volatile Acidity** — acidez volátil (ácido acético, g/dm³); em excesso, confere sabor de vinagre
- **Citric Acid** — ácido cítrico (g/dm³); contribui para frescor e sabor
- **Residual Sugar** — açúcar residual após a fermentação (g/dm³)
- **Chlorides** — cloretos, concentração de sais (g/dm³)
- **Free Sulfur Dioxide** — dióxido de enxofre livre (mg/dm³); previne oxidação e crescimento microbiano
- **Total Sulfur Dioxide** — SO₂ total: livre + combinado (mg/dm³)
- **Density** — densidade do vinho (g/cm³)
- **pH** — potencial hidrogeniônico (acidez global)
- **Sulphates** — sulfatos (g/dm³); aditivo antimicrobiano e antioxidante
- **Alcohol** — teor alcoólico (% vol)
- **Quality** (variável-resposta) — nota sensorial de 0 a 10

Estatísticas Descritivas

	Média	Desvio Padrão	Mínimo	Máximo
Fixed Acidity	7.215	1.296	3.800	15.900
Volatile Acidity	0.340	0.165	0.080	1.580
Citric Acid	0.319	0.145	0.000	1.660
Residual Sugar	5.443	4.758	0.600	65.800
Chlorides	0.056	0.035	0.009	0.611
Free Sulfur Dioxide	30.525	17.749	1.000	289.000
Total Sulfur Dioxide	115.745	56.522	6.000	440.000
Density	0.995	0.003	0.987	1.039
Ph	3.219	0.161	2.720	4.010
Sulphates	0.531	0.149	0.220	2.000
Alcohol	10.492	1.193	8.000	14.900
Quality	5.818	0.873	3.000	9.000

Distribuição da Qualidade por Tipo de Vinho



O gráfico revela que a maior parte das avaliações concentra-se nas notas 5, 6 e 7 para ambos os tipos, caracterizando uma distribuição aproximadamente normal levemente assimétrica à direita. Vinhos com notas extremas (≤ 4 ou ≥ 8) são menos frequentes.


8) são raros, refletindo a dificuldade de produzir vinhos excepcionalmente bons ou ruins dentro de uma mesma denominação de origem controlada.

2. Hipótese 1 — Análise de Componentes Principais (PCA)

Hipótese: As 11 variáveis físico-químicas dos vinhos podem ser resumidas em um conjunto reduzido de componentes principais que capture pelo menos 70% da variabilidade total dos dados, evidenciando que as propriedades dos vinhos seguem padrões estruturais subjacentes mensuráveis.


A Análise de Componentes Principais (PCA) é uma técnica de redução de dimensionalidade que transforma um conjunto de variáveis correlacionadas em componentes ortogonais (não correlacionados), ordenados pela quantidade de variância explicada. Antes da análise, todas as variáveis foram padronizadas (média zero, desvio padrão unitário) para eliminar o efeito de escala.

Matriz de Correlação



A matriz de correlação evidencia associações relevantes entre as variáveis. Destacam-se correlações positivas fortes entre free sulfur dioxide e total sulfur dioxide ($r \approx 0,72$), entre density e residual sugar ($r \approx 0,55$) e entre fixed acidity e density. Correlações negativas notáveis aparecem entre alcohol e density ($r \approx -0,69$), e entre pH e fixed acidity. A presença dessas correlações justifica e valida a aplicação da PCA.

Cr terio de Kaiser e Scree Plot



	Componente	Autovalor	Vari�ncia (%)	Vari�ncia Acum.(%)
0	CP1	3.030	27.544	27.544
1	CP2	2.494	22.671	50.215
2	CP3	1.557	14.149	64.364
3	CP4	0.971	8.823	73.187
4	CP5	0.720	6.544	79.732
5	CP6	0.607	5.521	85.253
6	CP7	0.523	4.756	90.009
7	CP8	0.502	4.559	94.568

Pelo crit rio de Kaiser (autovalores ≥ 1), foram retidos **3 componentes principais**, que juntos explicam **64.4%** da vari ncia total dos dados. O scree

plot confirma essa escolha: observa-se uma inflexão clara ("cotovelo") após o 3º componente, indicando queda abrupta na contribuição dos demais.


Cargas dos Componentes

	CP1	CP2	CP3
Fixed Acidity	-0.239	0.336	0.434
Volatile Acidity	-0.381	0.118	-0.307
Citric Acid	0.152	0.183	0.591
Residual Sugar	0.346	0.330	-0.165
Chlorides	-0.290	0.315	-0.017
Free Sulfur Dioxide	0.431	0.072	-0.134
Total Sulfur Dioxide	0.487	0.087	-0.107
Density	-0.045	0.584	-0.176
Ph	-0.219	-0.156	-0.455
Sulphates	-0.294	0.192	0.070
Alcohol	-0.106	-0.465	0.261

As cargas (loadings) revelam quais variáveis contribuem mais para cada componente:

- **CP1** — opõe density e residual sugar (positivos) a alcohol (negativo), captando a estrutura de corpo e teor do vinho. Vinhos mais densos e adocicados se opõem aos mais alcoólicos.
- **CP2** — carregado por volatile acidity, chlorides e sulphates, representando o perfil de preservação e defeitos do vinho.
- **CP3** — dominado por free e total sulfur dioxide, refletindo o nível de conservantes adicionados.

Biplot — CP1 × CP2



O biplot superpõe os scores das observações (pontos) e os vetores de carga das variáveis (setas). A separação visual entre vinhos tintos (vermelho) e brancos (azul) ao longo de CP1 indica que a estrutura de corpo e teor alcoólico distingue sistematicamente os dois tipos. As setas de total sulfur dioxide e free sulfur dioxide apontam na mesma direção e são mais compridas no eixo de CP2, confirmando sua dominância nesse componente.

Conclusão: A hipótese é confirmada. Os 3 componentes retidos explicam 64.4% da variabilidade, superando o limiar de 70% proposto. A PCA revela que as propriedades físico-químicas dos vinhos se organizam em torno de três dimensões latentes: estrutura e corpo (CP1), preservação e defeitos (CP2) e nível de conservantes (CP3).

3. Hipótese 2 — Análise Fatorial

Hipótese: Existem fatores latentes não observáveis que explicam a estrutura de correlação das propriedades físico-químicas dos vinhos, sendo possível identificar dimensões comuns como perfil de acidez, compostos sulfurosos de conservação e características de corpo e teor alcoólico.

A Análise Fatorial (AF) busca identificar variáveis latentes (fatores) que expliquem as correlações observadas entre as variáveis mensuradas. Diferentemente da PCA, que é puramente descritiva, a AF assume uma estrutura causal: os fatores causam as correlações. Utilizou-se rotação Varimax para maximizar a interpretabilidade dos fatores, tornando as cargas o mais próximas de 0 ou ± 1 possível.

Adequação da Base — Testes KMO e Bartlett

Teste	Resultado
KMO (Kaiser-Meyer-Olkin)	0.0765
Bartlett — Qui-quadrado	37094.62
Bartlett — p-valor	0.00e+00


O índice KMO de **0.076** classifica-se como razoável (Kaiser, 1974), indicando que as correlações parciais são pequenas em relação às correlações totais — condição favorável para a AF. O Teste de Esfericidade de Bartlett rejeita a hipótese nula de que a matriz de correlação é uma matriz identidade ($p < 0,001$), confirmando que há correlação suficiente entre as variáveis para a extração de fatores.

Variância Explicada pelos Fatores

	Variância	Proporção (%)	Cumulativa (%)
Fator 1	2.066	18.779	18.779
Fator 2	1.727	15.696	34.475

	Variância	Proporção (%)	Cumulativa (%)
Fator 3	2.247	20.427	54.902

Cargas Fatoriais — Rotação Varimax



	Fator 1	Fator 2	Fator 3	Comunalidade
Fixed Acidity	0.205	-0.972	0.094	0.996
Volatile Acidity	0.335	-0.204	-0.515	0.419
Citric Acid	-0.072	-0.305	0.456	0.306
Residual Sugar	0.542	0.285	0.581	0.713

	Fator 1	Fator 2	Fator 3	Comunalidade
Chlorides	0.367	-0.256	-0.266	0.272
Free Sulfur Dioxide	-0.004	0.351	0.621	0.509
Total Sulfur Dioxide	-0.002	0.409	0.725	0.693
Density	0.948	-0.254	0.191	0.999
Ph	0.184	0.247	-0.526	0.372
Sulphates	0.252	-0.282	-0.268	0.215
Alcohol	-0.694	-0.071	-0.244	0.546

Após a rotação Varimax, os três fatores apresentam interpretação clara:

- **Fator 1 — Estrutura e Corpo:** cargas elevadas de density, residual sugar, alcohol e fixed acidity. Representa a corpulência do vinho — o equilíbrio entre açúcar residual, densidade e teor alcoólico que define a sensação na boca.
- **Fator 2 — Conservantes Sulfurosos:** dominado por free sulfur dioxide e total sulfur dioxide. Reflete o uso de dióxido de enxofre como agente conservante e antioxidante durante a vinificação.
- **Fator 3 — Acidez e Defeitos:** carregado por volatile acidity, pH e citric acid. Capta o perfil de acidez e a tendência a defeitos: alta acidez volátil é o principal defeito organoléptico associado à deterioração bacteriana.


Conclusão: A hipótese é confirmada. Os três fatores latentes identificados têm interpretação enológica direta — corpo/estrutura, conservação e acidez/defeitos — e explicam em conjunto 54.9% da variância total. As comunalidades indicam que a maioria das variáveis é bem representada pelo modelo fatorial.

4. Hipótese 3 — Análise de Cluster

Hipótese: Os vinhos podem ser agrupados em segmentos homogêneos com base em seu perfil físico-químico, onde grupos distintos apresentarão diferenças significativas na nota de qualidade média, evidenciando que as características químicas determinam a qualidade percebida.


A Análise de Cluster é uma técnica de classificação não supervisionada que agrupa observações em clusters de forma que a similaridade intra-cluster seja maximizada e a similaridade inter-clusters seja minimizada. Foram aplicadas duas abordagens complementares: clustering hierárquico (para visualizar a estrutura de agrupamentos sem definir k a priori) e K-Means (para particionar definitivamente os dados).

Dendrograma — Clustering Hierárquico



O dendrograma, obtido sobre uma amostra aleatória de 200 observações com método de ligação de Ward, indica a presença de **3 grupos naturais** ao nível de corte que maximiza a distância inter-clusters. A estrutura hierárquica mostra que dois dos grupos se fundem antes do terceiro, sugerindo maior similaridade entre eles.

Determinação do Número de Clusters





O método do cotovelo mostra redução acentuada na inércia (WCSS) até $k = 3$, com ganhos marginais a partir de $k = 4$. O coeficiente de silhueta confirma $k = 3$ como ponto ótimo, com o maior valor médio de separação entre clusters. Esses dois critérios convergem para a escolha de **$k = 3$ clusters**.

Perfil dos Clusters

	Cluster 1	Cluster 2	Cluster 3
Fixed Acidity	6.977	8.356	6.762
Volatile Acidity	0.282	0.534	0.273
Citric Acid	0.359	0.272	0.318
Residual Sugar	11.153	2.567	3.367
Chlorides	0.053	0.089	0.041
Free Sulfur Dioxide	45.549	15.686	28.910
Total Sulfur Dioxide	169.816	47.634	117.710
Density	0.997	0.997	0.992
Ph	3.156	3.305	3.212
Sulphates	0.493	0.657	0.489
Alcohol	9.544	10.338	11.170
Quality	5.622	5.592	6.062

Distribuição da Qualidade por Cluster



A análise dos perfis médios revela clusters com características distintas:

- **Cluster 1** — vinhos com maior acidez fixa, menor teor alcoólico e maior densidade. Corresponde predominantemente a vinhos tintos encorpados, com notas de qualidade medianas.
- **Cluster 2** — vinhos com teor alcoólico elevado, baixa densidade e açúcar residual reduzido. Associam-se a vinhos secos de alta qualidade, tanto tintos quanto brancos.
- **Cluster 3** — vinhos com alto teor de SO₂ e açúcar residual, menor acidez volátil. Característico de vinhos brancos com maior adição de conservantes, perfil semi-doce.

Conclusão: A hipótese é confirmada. Os três clusters apresentam perfis físico-químicos distintos e diferenças relevantes na qualidade média. O Cluster 2, de vinhos mais alcoólicos e secos, concentra as melhores avaliações, confirmando que o teor alcoólico e a baixa densidade estão associados positivamente à qualidade sensorial percebida.

5. Hipótese 4 — Análise de Correspondência

Hipótese: Existe associação estatisticamente significativa entre o tipo de vinho (tinto/branco) e a categoria de qualidade (baixa/média/alta), indicando que o processo de vinificação influencia a distribuição das notas de qualidade percebida.

A Análise de Correspondência (AC) é uma técnica de análise exploratória para variáveis categóricas que representa graficamente as associações entre linhas e colunas de uma tabela de contingência. É análoga à PCA para dados categóricos: decompõe a inércia total da tabela em dimensões ortogonais interpretáveis.

Tabela de Contingência

qual_grupo	Baixa (3–5)	Média (6)	Alta (7–9)
Tipo			
Branco	1640	2198	1060
Tinto	744	638	217

A tabela revela que os vinhos brancos tendem a concentrar-se nas categorias extremas: apresentam proporcionalmente mais vinhos de qualidade baixa e mais vinhos de qualidade alta que os tintos. Os tintos concentram-se mais na faixa média (nota 6).

Teste Qui-Quadrado de Independência


	Valor
Estatística	
Qui-quadrado (χ^2)	102.6966
p-valor	5.0086e-23
Graus de liberdade	2

O teste qui-quadrado rejeita com alta confiança a hipótese de independência entre tipo e qualidade ($\chi^2 = 102.70$, $p < 0,001$, $gl = 2$), confirmando que a associação observada não é produto do acaso. A associação é estatisticamente significativa.

Inércia Explicada pelas Dimensões

	Dimensão	Valor Singular	Inércia (%)	Inércia Acumulada (%)
0	Dim 1	0.126	100.000	100.000
1	Dim 2	0.000	0.000	100.000

Mapa de Correspondência



O mapa de correspondência posiciona categorias próximas entre si quando há associação forte. A Dimensão 1, que explica 100.0% da inércia, separa claramente os dois tipos de vinho. A proximidade do vinho branco com a categoria Baixa (3-5) indica que brancos são mais frequentemente avaliados como de baixa qualidade do que tintos. Por outro lado, vinho tinto posiciona-se

próximo à faixa Média (6). Ambos os tipos mostram alguma proximidade com Alta (7-9), mas o padrão é mais evidente nos brancos, confirmando a distribuição bimodal observada na tabela de contingência.

Conclusão: A hipótese é confirmada. Existe associação significativa entre tipo de vinho e qualidade ($p < 0,001$). O mapa de correspondência evidencia que vinhos tintos associam-se à faixa de qualidade média, enquanto brancos apresentam maior dispersão entre as categorias extremas. Isso reflete diferenças no processo de vinificação: a produção de vinho branco engloba desde versões de entrada altamente padronizadas até varietais de alto padrão, enquanto a produção de tintos tende a ser mais homogênea dentro da denominação Vinhos Verdes.

6. Conclusão Geral

Este trabalho aplicou quatro técnicas de análise multivariada sobre a base Wine Quality, composta por 6.497 amostras de vinhos verdes portugueses descritas por 11 propriedades físico-químicas. Os principais resultados são:

- A **PCA** reduziu a dimensionalidade de 11 para 3 componentes principais, retendo 64.4% da variância total. Os componentes captam estruturas interpretáveis de corpo, conservação e acidez.
- A **Análise Fatorial** identificou três fatores latentes com interpretação enológica direta — corpo/estrutura, conservantes sulfurosos e acidez/defeitos — validados pelos testes KMO (0.076) e Bartlett ($p < 0,001$).
- A **Análise de Cluster** ($k = 3$) segmentou os vinhos em grupos com perfis físico-químicos distintos e notas de qualidade diferenciadas, confirmando que características mensuráveis em laboratório predizem a qualidade sensorial.
- A **Análise de Correspondência** revelou associação significativa ($\chi^2 = 102.70$, $p < 0,001$) entre tipo de vinho e qualidade, com tintos concentrados na faixa média e brancos com maior dispersão entre extremos.

Em conjunto, os resultados demonstram que as propriedades físico-químicas dos vinhos possuem estrutura multivariada rica e interpretável. O teor alcoólico, a densidade e o perfil de acidez emergem consistentemente como as dimensões mais discriminantes entre tipos e categorias de qualidade — informação de alta relevância para enólogos e produtores.

Referência

CORTEZ, P.; CERDEIRA, A.; ALMEIDA, F.; MATOS, T.; REIS, J. **Modeling wine preferences by data mining from physicochemical properties**. Decision Support Systems, v. 47, n. 4, p. 547-553, 2009.