Curso de Ciência de Dados e Inteligência Artificial
Análise Multivariada

Modelagem Estatística Multivariada e Avaliação de Performance

Relatório técnico – Comportamento, satisfação e padrão financeiro de clientes de uma rede de varejo

Aluno(a): _____

Novembro de 2026

Sumário

1. Base de dados e visão geral
2. Parte I – Comparação do Score de Satisfação entre regiões (ANOVA)
3. Parte II – Efeito conjunto da Região sobre Gasto Online, Gasto Loja e NPS (MANOVA)
4. Parte II (Questão 3) – Função discriminante para o Status de Fidelidade
5. Parte III – Mapeamento perceptual dos perfis (Escalonamento Multidimensional)
6. Parte IV – Relação entre Engajamento Operacional e Retorno Financeiro/Percepção (Correlação Canônica)
7. Síntese para a tomada de decisão

Cada seção apresenta: **Metodologia** (justificativa da escolha do método), **Validação** (testes de pressupostos), **Resultados e Tabelas** e **Interpretação Negocial**.

1. Base de dados e visão geral

A base contém **300 clientes** e foi construída por simulação a partir das regras e distribuições descritas no enunciado. Como foi utilizado um gerador pseudoaleatório diferente do SAS, os valores individuais não coincidem necessariamente com os do arquivo original. Portanto, este relatório deve ser entendido como uma **reprodução independente do procedimento**, e não como uma cópia da base SAS; resultados numéricos e conclusões podem variar. A distribuição observada foi: Norte = 95, Sul = 105 e Centro = 100; Status 0 = 160 (53%) e Status 1 = 140 (47%). Região e status não apresentaram associação estatisticamente significativa ($\chi^2 = 2{,}72$; gl = 2; p = 0,2561). Não há valores ausentes.

Tabela 1 – Estatísticas descritivas das variáveis contínuas (n = 300)

Variável	Média	Desvio-padrão	Mínimo	Mediana	Máximo	Assimetria	Curtose (exc.)
Gasto Online	1.078,52	184,39	556,85	1.095,57	1.545,26	-0,16	-0,22
Gasto Loja	574,02	122,76	231,16	578,39	816,22	-0,39	-0,13
Freq. Online	16,65	4,28	6,00	17,00	28,00	-0,10	-0,40
Freq. Loja	8,08	3,04	0,00	8,00	14,00	-0,39	-0,13
Score de Satisfação	7,63	1,16	4,50	7,60	10,00	0,07	-0,56
Tempo de Relação	24,46	10,33	1,00	25,00	52,00	0,09	-0,38
NPS	87,38	8,65	67,00	87,00	100,00	-0,11	-1,21

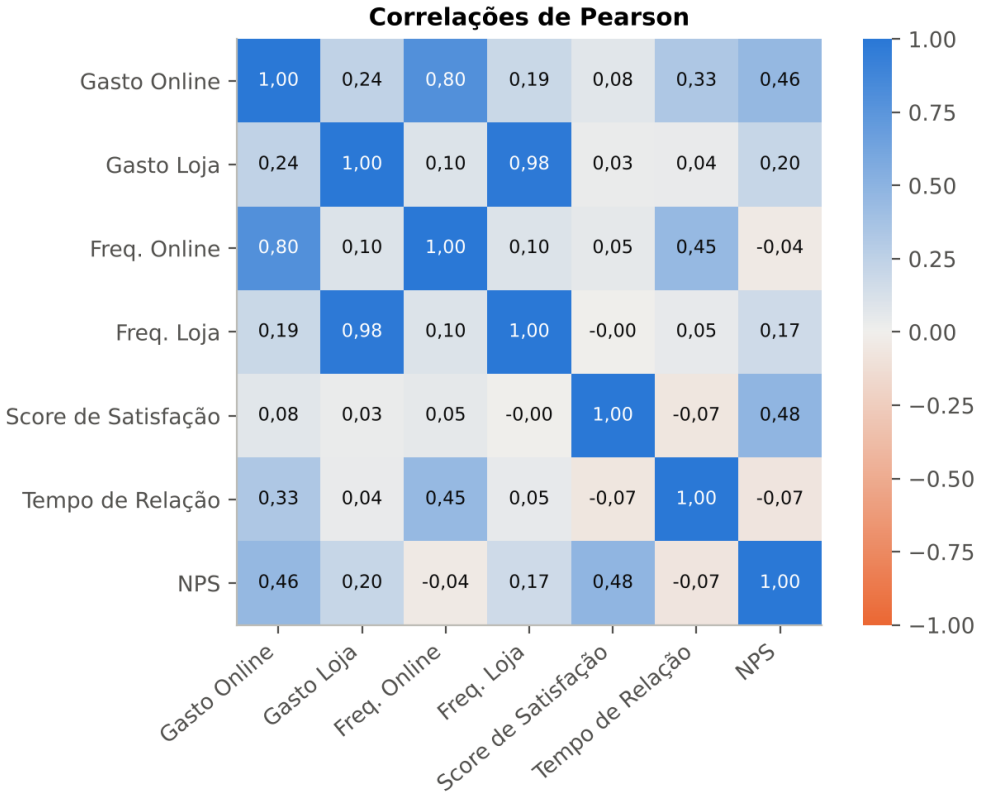


Figura 1 – Matriz de correlações. Destacam-se Freq. Loja × Gasto Loja (0,98), Freq. Online × Gasto Online (0,80) e Gasto Online × NPS (0,46).

2. Parte I – Comparação do Score de Satisfação entre regiões

2.1 Metodologia

A variável resposta (Score de Satisfação) é **quantitativa contínua** e o fator explicativo (Região) é **categórico com três níveis independentes** (cada cliente pertence a uma única região). O objetivo é testar simultaneamente H_0: $\mu_{Norte} = \mu_{Sul} = \mu_{Centro}$. A ferramenta adequada é a **Análise de Variância (ANOVA) de um fator**, que decompõe a variabilidade total em uma parcela atribuída às diferenças entre as médias das regiões e outra atribuída à variação dentro das regiões, comparando-as pela estatística F. Realizar três testes t em pares não é adequado, pois inflaria a taxa de erro tipo I global ($1 - 0{,}95^3 \approx 14\%$). Havendo rejeição de H_0, aplica-se um procedimento de **comparações múltiplas post hoc** (Tukey HSD, apropriado para todas as comparações par a par com controle do erro global; Bonferroni como confirmação) para identificar quais regiões diferem.

2.2 Validação dos pressupostos

- **Independência das observações:** garantida pelo desenho – cada cliente é observado uma vez e pertence a uma só região.
- **Normalidade:** o teste de Shapiro-Wilk sobre os **resíduos** do modelo (que é o pressuposto formal) não rejeita a normalidade (W = 0,9956; p = 0,5548), resultado confirmado por Kolmogorov-Smirnov (D = 0,0467; p = 0,5150) e pelo Q-Q plot (Figura 2). Por grupo, Norte (p = 0,0494) e Centro (p = 0,0248) apresentam desvios marginais, explicados pelo truncamento da nota em 1 e 10 (efeito teto no Centro). Assimetrias e curtoses estão entre −0,6 e 0,6 e os grupos têm n ≥ 95, de modo que a ANOVA é robusta (Teorema Central do Limite).
- **Homogeneidade das variâncias:** Levene (centrado na média) F = 0,583, p = 0,5588; Brown-Forsythe (mediana) F = 0,592, p = 0,5536; Bartlett χ^2 = 0,555, p = 0,7575. Nenhum rejeita a igualdade das variâncias (desvios-padrão entre 0,99 e 1,06).

Tabela 2 – Estatísticas descritivas do Score de Satisfação por região

Região	n	Média	Desvio-padrão	Mediana	Assimetria	Curtose	Shapiro W	p-valor
Norte	95	6,956	0,987	6,90	0,54	0,02	0,9733	0,0494
Sul	105	7,541	0,994	7,50	-0,23	0,16	0,9866	0,3737
Centro	100	8,369	1,057	8,30	-0,30	-0,54	0,9706	0,0248

2.3 Resultados

Tabela 3 – Quadro da ANOVA de um fator

Fonte de variação	gl	Soma de quadrados	Quadrado médio	F	p-valor
Entre regiões (Regiao)	2	98,627	49,314	48,023	< 0,0001
Dentro das regiões (resíduo)	297	304,982	1,027		
Total	299	403,609			

A estatística F = 48,02 (gl = 2; 297) é altamente significativa (p < 0,0001): rejeita-se H_0. O tamanho de efeito é grande: η^2 = 0,244 e ω^2 = 0,239, isto é, cerca de **24% da variabilidade da satisfação é explicada pela região**. Como verificação de robustez, a ANOVA de Welch (que não exige variâncias iguais) fornece F = 46,73 (gl = 2; 197,1), p < 0,0001, e o teste não paramétrico de Kruskal-Wallis fornece H = 73,30, p < 0,0001 – a conclusão é a mesma por todos os caminhos.

Tabela 4 – Comparações múltiplas post hoc (QME = 1,0269, gl = 297)

Comparação	Diferença de médias	IC 95% (Tukey)	p ajustado Tukey	p ajustado Bonferroni	Difere?
Sul − Norte	0,585	[0,247; 0,923]	0,0002	0,0002	Sim
Centro − Norte	1,413	[1,071; 1,755]	< 0,0001	< 0,0001	Sim
Centro − Sul	0,828	[0,494; 1,162]	< 0,0001	< 0,0001	Sim

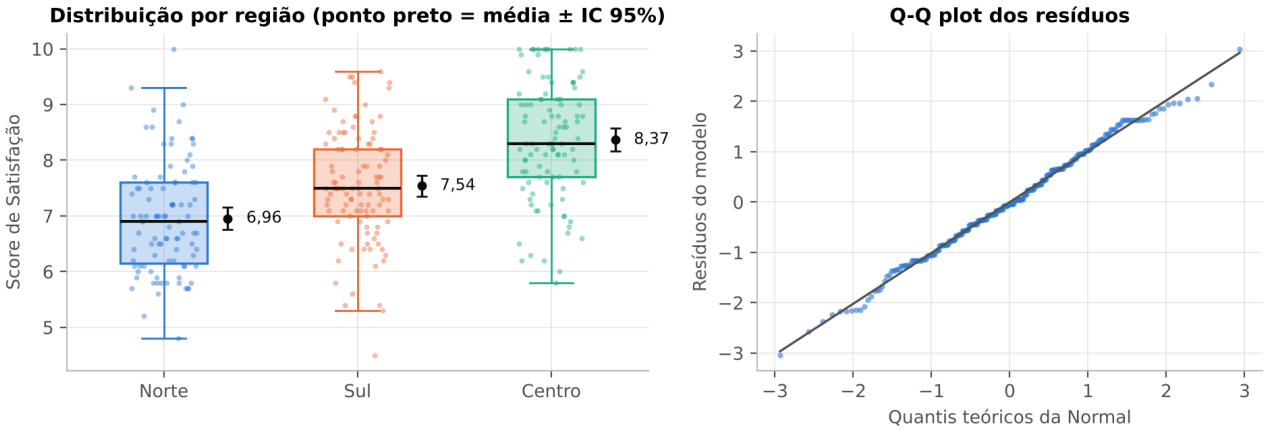


Figura 2 – Score de Satisfação por região e diagnóstico de normalidade dos resíduos da ANOVA.

2.4 Interpretação negocial

As três regiões diferem entre si, com ordenação nítida: **Norte (6,96) < Sul (7,54) < Centro (8,37)**. A distância entre o Norte e o Centro é de aproximadamente 1,4 ponto em uma escala de 10 – uma diferença substantiva, não apenas estatística. Recomenda-se: (i) priorizar o Norte em ações de melhoria de experiência (atendimento, prazos de entrega, sortimento), pois é a região com maior espaço de ganho; (ii) estudar as práticas operacionais do Centro como referência interna (benchmark); (iii) no Centro, como parte dos clientes já atinge a nota máxima (efeito teto), a métrica de satisfação perde sensibilidade e deve ser complementada por indicadores como NPS e recompra; (iv) metas de satisfação devem ser regionalizadas, já que uma meta única penalizaria o Norte e seria pouco desafiadora para o Centro.

3. Parte II – Efeito conjunto da Região sobre Gasto Online, Gasto Loja e NPS

3.1 Metodologia

Agora há **três variáveis dependentes quantitativas medidas no mesmo cliente** e, portanto, correlacionadas (Gasto Online × NPS: r = 0,46; Gasto Online × Gasto Loja: r = 0,24; esfericidade de Bartlett p < 0,0001). O fator continua sendo a Região (3 grupos independentes). O método adequado é a **Análise de Variância Multivariada (MANOVA)**, que testa H_0: $\boldsymbol{\mu}_{Norte} = \boldsymbol{\mu}_{Sul} = \boldsymbol{\mu}_{Centro}$, em que cada $\boldsymbol{\mu}$ é o vetor de médias (Gasto Online, Gasto Loja, NPS). A MANOVA compara a matriz de somas de quadrados e produtos cruzados entre grupos (**H**) com a matriz dentro dos grupos (**E**), considerando variâncias e covariâncias simultaneamente, e controla o erro tipo I global em um único teste. Os quatro critérios clássicos são funções dos autovalores de $\mathbf{E}^{-1}\mathbf{H}$ (λ_1 = 0,1622, λ_2 = 0,0608).

3.2 Validação dos pressupostos

- **Independência:** garantida pelo desenho amostral; **tamanho amostral**: todos os grupos têm n ≥ 95, muito acima do número de variáveis dependentes (3).
- **Normalidade multivariada:** os testes de Mardia por grupo não rejeitam a normalidade (Tabela 6). Nos resíduos combinados, a curtose multivariada é levemente inferior à esperada (b_2 = 13,39 vs. 15; p = 0,0109), efeito do truncamento do NPS em 100 (distribuição achatada, platicúrtica), que não compromete o teste dado o tamanho amostral.
- **Homogeneidade das matrizes de covariâncias:** o teste M de Box não rejeita H_0 (p = 0,7134); os testes de Levene univariados também não rejeitam.
- **Linearidade e ausência de multicolinearidade entre as VDs:** as correlações são moderadas (máx. 0,46), indicando variáveis relacionadas, mas não redundantes – situação ideal para a MANOVA.

Tabela 5 – Médias (desvios-padrão) das variáveis dependentes por região

Região	Gasto Online (R$)	Gasto Loja (R$)	NPS
Norte	993,03 (184,22)	543,40 (125,02)	83,89 (8,64)
Sul	1.150,72 (167,21)	605,26 (120,07)	88,00 (8,57)
Centro	1.083,94 (168,89)	570,30 (116,53)	90,05 (7,67)

Tabela 6 – Testes de pressupostos da MANOVA

Teste de pressuposto	Estatística	p-valor
Mardia – assimetria (Norte)	7,78	0,6504
Mardia – assimetria (Sul)	14,43	0,1542
Mardia – assimetria (Centro)	10,98	0,3591
Mardia – curtose (Norte)	-1,84	0,0655
Mardia – curtose (Sul)	-1,27	0,2056
Mardia – curtose (Centro)	-1,23	0,2198
M de Box (homog. das matrizes de covariâncias)	8,88 (gl = 12)	0,7134
Esfericidade de Bartlett (correlação entre as VDs)	91,38 (gl = 3)	< 0,0001
Levene – Gasto Online	1,138	0,3219
Levene – Gasto Loja	0,042	0,9592
Levene – NPS	2,411	0,0915

3.3 Resultados

Tabela 7 – Testes multivariados para o efeito da Região

Critério multivariado	Valor	F aproximado	gl num.	gl den.	p-valor
Lambda de Wilks	0,8111	10,854	6	590,0	< 0,0001
Traço de Pillai	0,1969	10,777	6	592,0	< 0,0001
Traço de Hotelling-Lawley	0,2231	10,949	6	391,6	< 0,0001
Maior raiz de Roy	0,1622	16,008	3	296,0	< 0,0001

Todos os critérios rejeitam H_0 (p < 0,0001): **o vetor de médias difere entre as regiões**. O Lambda de Wilks (0,811) confirma a diferença multivariada. Seu complemento ($1 - \Lambda = 0{,}189$) é apenas uma transformação descritiva do Lambda e não deve ser interpretado diretamente como percentual de variância explicado ou como η^2 multivariado. Para discutir magnitude, utilizam-se os

tamanhos de efeito das ANOVAs univariadas (Tabela 8), que mostram efeitos distintos para cada variável. Como o M de Box não foi significativo, Wilks é o critério de referência; o Traço de Pillai, o mais robusto a violações, confirma o resultado. A maior raiz de Roy, também significativa, indica que a maior parte da diferença se concentra em uma dimensão. As duas funções discriminantes associadas (Tabela 9) mostram que a primeira dimensão (73% da separação) é dominada por **Gasto Online**, e a segunda por **NPS**.

Tabela 8 – ANOVAs univariadas de acompanhamento

Variável dependente	F (2; 297)	p-valor	p Bonferroni (×3)	η²
Gasto Online	20,715	< 0,0001	< 0,0001	0,122
Gasto Loja	6,641	0,0015	0,0045	0,043
NPS	13,831	< 0,0001	< 0,0001	0,085

Tabela 9 – Coeficientes padronizados das funções discriminantes da MANOVA (escala relativa)

Variável	Função 1	Função 2
Gasto Online	1,000	-0,464
Gasto Loja	0,426	-0,267
NPS	0,204	1,000

Tabela 10 – Pares de regiões significativamente diferentes (Tukey, 5%)

Variável	Norte × Sul	Norte × Centro	Sul × Centro
Gasto Online	✓	✓	✓
Gasto Loja	✓	–	–
NPS	✓	✓	–

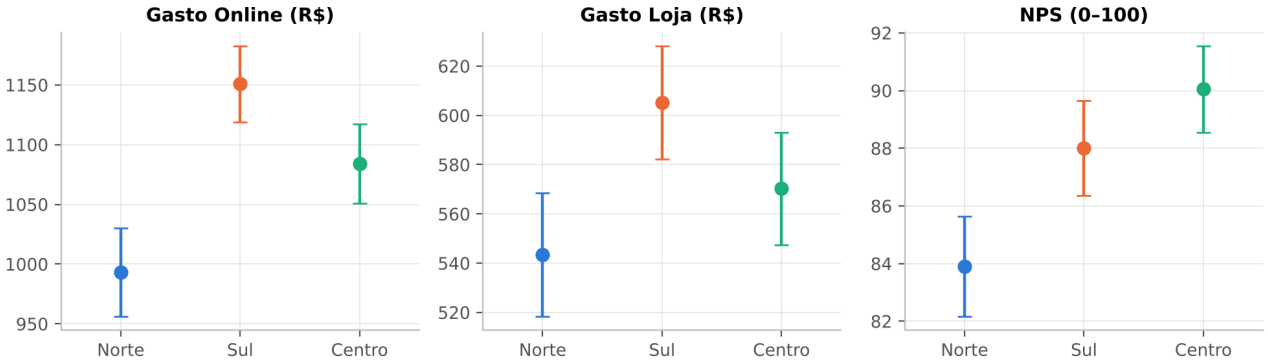


Figura 3 – Médias por região e intervalos de confiança de 95% para as três variáveis dependentes.

3.4 Por que a MANOVA pode divergir de três ANOVAs separadas

1. **Controle do erro tipo I:** três ANOVAs a 5% elevam a probabilidade de pelo menos um falso positivo para $1 - 0{,}95^3 \approx 14{,}3\%$. A MANOVA realiza um único teste ao nível nominal de 5%.
2. **Uso da estrutura de covariância:** as ANOVAs tratam cada variável isoladamente e ignoram as correlações. A MANOVA avalia o afastamento entre os centróides dos grupos em uma métrica que leva em conta as covariâncias (distância de Mahalanobis). Duas variáveis correlacionadas carregam informação parcialmente redundante; a MANOVA não a "conta duas vezes", o que pode reduzir a evidência em relação às análises isoladas.
3. **Efeitos de combinação:** grupos podem não diferir de forma relevante em nenhuma variável isolada e, ainda assim, diferir em uma combinação linear delas (por exemplo, quando a relação entre gasto e NPS muda de sentido entre regiões). Nesses casos a MANOVA detecta diferenças

invisíveis às ANOVAs. O inverso também ocorre: uma diferença univariada fraca pode não ser significativa no teste multivariado, que "dilui" o efeito entre os graus de liberdade das três variáveis.

4. **Nesta base**, ambos os enfoques concordam (todas as ANOVAs significativas mesmo após Bonferroni), mas a MANOVA acrescenta que as diferenças regionais **não** são três fenômenos independentes: elas se organizam em duas dimensões (gasto digital e percepção/NPS), e o padrão de pares difere por variável (Tabela 10) – Sul lidera em gasto, Centro em NPS.

3.5 Interpretação negocial

A região afeta o "pacote" de desempenho do cliente, mas de forma diferente para cada componente. O **Sul** é a região de maior valor financeiro (Gasto Online médio de R$ 1.151, cerca de R$ 158 acima do Norte), o **Centro** combina gasto intermediário com o maior NPS (90,0), e o **Norte** é inferior em todas as métricas. O gasto em loja física varia pouco entre regiões ($\eta^2 = 0{,}043$; só Norte × Sul difere), logo as diferenças regionais são essencialmente de **canal digital** e de **percepção da marca**. Implicações: investir em ativação digital no Norte; no Centro, converter a boa percepção em gasto (programas de indicação, ofertas personalizadas); no Sul, proteger a base de alto valor e monitorar se o NPS acompanha o gasto. Avaliar só a satisfação (Parte I) levaria a concluir que o Centro é a melhor região; a visão multivariada mostra que, em valor financeiro, o Sul é superior.

4. Parte II (Questão 3) – Função discriminante para o Status de Fidelidade

4.1 Metodologia

O problema tem uma **variável dependente categórica com dois grupos conhecidos a priori** (Status 0 e 1) e **cinco preditoras quantitativas contínuas**. Deseja-se (a) encontrar a combinação linear das preditoras que maximiza a separação entre os grupos e (b) classificar novos clientes. Essa é exatamente a proposta da **Análise Discriminante Linear de Fisher**: a função $Z = a_1X_1 + \ldots + a_5X_5$ é escolhida de modo a maximizar a razão entre a variabilidade entre grupos e a variabilidade dentro dos grupos, o que, para dois grupos, leva a $\mathbf{a} = \mathbf{S}_p^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_0)$, em que $\mathbf{S}_p$ é a matriz de covariâncias combinada. A forma linear é justificada quando as matrizes de covariâncias dos grupos são iguais (caso contrário, seria indicada a forma quadrática). A classificação usa o ponto de corte entre os centróides dos grupos, com probabilidades a priori iguais e, como sensibilidade, proporcionais aos tamanhos dos grupos.

4.2 Validação dos pressupostos

- **Normalidade multivariada em cada grupo:** Mardia não rejeita (Tabela 12).
- **Igualdade das matrizes de covariâncias:** M de Box $\chi^2 = 23{,}10$, gl = 15, p = 0,0820 – não se rejeita a homogeneidade ao nível de 5%, justificando a função **linear**.
- **Multicolinearidade:** há colinearidade forte entre Gasto Loja e Freq. Loja ($r = 0{,}98$; VIF ≈ 28) e moderada entre Gasto Online e Freq. Online ($r = 0{,}80$; VIF ≈ 3,4). Isso não prejudica a capacidade de classificação, mas torna os coeficientes padronizados instáveis e de sinais opostos; por isso a interpretação combina coeficientes e cargas estruturais.
- **Tamanho amostral:** 160 e 140 clientes, isto é, mais de 28 observações por preditora no menor grupo (mínimo usual: 20).

Tabela 11 – Testes univariados de igualdade de médias entre os grupos

Variável	Média Status 0	Média Status 1	Λ de Wilks	F (1; 298)	p-valor
Gasto Online	991,03	1.178,51	0,7418	103,71	< 0,0001
Gasto Loja	549,61	601,91	0,9547	14,15	0,0002
Freq. Online	16,91	16,36	0,9958	1,26	0,2630
Freq. Loja	7,53	8,71	0,9623	11,69	0,0007
Tempo de Relação	24,93	23,92	0,9976	0,71	0,3994

Tabela 12 – Pressupostos da análise discriminante

Teste de pressuposto	Estatística	p-valor
Mardia – assimetria (Status 0)	22,11	0,9557
Mardia – assimetria (Status 1)	23,66	0,9271
Mardia – curtose (Status 0)	-1,43	0,1514
Mardia – curtose (Status 1)	-1,07	0,2842
M de Box	23,10 (gl = 15)	0,0820

Tabela 13 – Fatores de inflação da variância

Variável	VIF
Gasto Online	3,37
Gasto Loja	28,65
Freq. Online	3,37
Freq. Loja	27,61
Tempo de Relação	1,25

4.3 A função discriminante

A função é altamente significativa: Λ de Wilks = 0,0671, χ^2 = 798,5 (gl = 5), p < 0,0001; autovalor = 13,913; **correlação canônica = 0,9659** (93% da variância do escore é explicada pela pertença ao grupo). A distância de Mahalanobis entre os centróides é D^2 = 55,53 (T^2 de Hotelling: F = 818,1; gl = 5; 294). Centróides: Status 0 = 2,360; Status 1 = 9,812 (escala com variância intra-grupo unitária).

Tabela 14 – Coeficientes e cargas da função discriminante

Variável	Coef. não padronizado	Coef. padronizado	Carga estrutural (intra-grupos)	Correlação com o escore (amostra total)
Gasto Online	0,03719	5,916	0,158	0,526
Gasto Loja	-0,04778	-5,741	0,058	0,220
Freq. Online	-1,33798	-5,726	-0,017	-0,067
Freq. Loja	1,89434	5,664	0,053	0,201
Tempo de Relação	0,00527	0,055	-0,013	-0,051
Constante	-5,8376			

Pesos padronizados. Em valor absoluto, os maiores pesos padronizados são de Gasto Online (5,92), Gasto Loja (-5,74), Freq. Online (-5,73) e Freq. Loja (5,66); Tempo de Relação tem peso praticamente nulo (0,055). Entretanto, a colinearidade elevada entre Gasto Loja e Freq. Loja (VIF ≈ 28) e, em menor grau, entre Gasto Online e Freq. Online torna esses coeficientes **sensíveis e**

potencialmente instáveis: os sinais opostos dentro de cada par gasto/frequência são consequência dessa colinearidade. Assim, não é adequado interpretar isoladamente os sinais e magnitudes dos coeficientes, nem concluir que a função representa exatamente um índice de ticket médio. As cargas estruturais e as correlações com o escore também são relativamente modestas; a evidência mais clara é a diferença univariada em **Gasto Online** (Tabela 11), acompanhada por diferenças menores em Gasto Loja e Freq. Loja. Vale notar que, pela regra de geração dos dados, o status de fidelidade só atua sobre o Gasto Online; as diferenças observadas no canal físico são, portanto, provavelmente flutuação amostral desta base. A função separa muito bem os grupos nesta base simulada, mas a contribuição individual das variáveis deve ser interpretada com cautela.

4.4 Capacidade de classificação

Tabela 15 – Matriz de confusão por resubstituição (a priori iguais)

Grupo real	Previsto 0	Previsto 1	Total	% correto
Inativo/Baixo Risco (0)	160	0	160	100,0%
Ativo/Alto Valor (1)	0	140	140	100,0%

Tabela 16 – Matriz de confusão por validação cruzada “deixe-um-fora” (Lachenbruch)

Grupo real	Previsto 0	Previsto 1	Total	% correto
Inativo/Baixo Risco (0)	160	0	160	100,0%
Ativo/Alto Valor (1)	0	140	140	100,0%

Tabela 17 – Validação com amostra de teste (função estimada em 210 clientes, aplicada a 90 novos)

Grupo real	Previsto 0	Previsto 1	Total	% correto
Inativo/Baixo Risco (0)	48	0	48	100,0%
Ativo/Alto Valor (1)	0	42	42	100,0%

A taxa de erro aparente (APER), a taxa de erro estimada por validação cruzada e a taxa de erro na amostra de teste foram, respectivamente, 0,0%, 0,0% e 0,0%. Com probabilidades a priori proporcionais (π_1 = 0,467) o resultado é idêntico (erro de 0,0%). O desempenho supera com folga os critérios de referência: chance proporcional C_{pro} = 50,2% e chance máxima C_{max} = 53,3% (a regra de 25% acima da chance exigiria ≥ 62,8%); o Q de Press = 300,0 é muito superior ao valor crítico $\chi^2_{1;\ 0,01}$ = 6,63. A separação perfeita é um resultado desta base simulada (o status adiciona R$ 200 ao gasto online, com ruído de desvio-padrão R$ 15) e não deve ser generalizada: não se deve atribuir toda a separação a um único indicador nem tratar a função como regra causal, e o desempenho deve ser validado em dados externos antes de qualquer aplicação real.

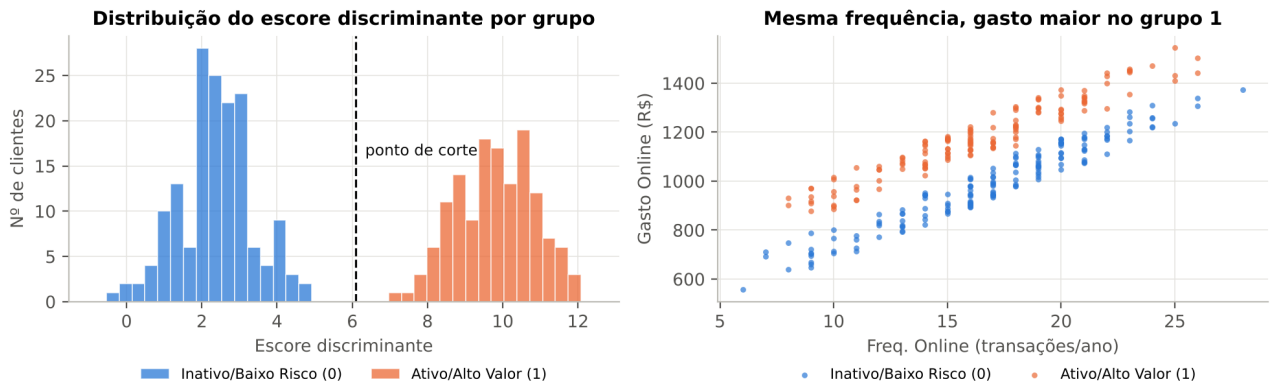


Figura 4 – Separação obtida pela função discriminante (esq.) e a origem da separação: para cada nível de frequência online, os clientes Ativos/Alto Valor gastam sistematicamente mais (dir.).

4.5 Interpretação negocial

Nesta base, o que mais distingue o cliente Ativo/Alto Valor é o **Gasto Online**: a frequência online e o tempo de relação são estatisticamente iguais nos dois grupos, enquanto o gasto online é, em média, cerca de R$ 190 maior no grupo 1. Isso sugere, como **hipótese gerencial a validar em dados reais**, que o valor gasto no canal digital – e não a contagem de transações – seja um bom indicador inicial do perfil de alto valor. Implicações possíveis: (i) usar o gasto online como indicador de acompanhamento do programa de fidelidade; (ii) testar campanhas de aumento de cesta (cross-sell, up-sell, frete grátis acima de um valor) para clientes do grupo 0, medindo o efeito com grupo de controle; (iii) aplicar a função como regra de pontuação somente após validá-la em dados externos, pois a separação perfeita aqui observada é específica desta amostra simulada.

5. Parte III – Mapeamento perceptual dos perfis (Escalonamento Multidimensional)

5.1 Metodologia

O objetivo é representar os 300 clientes em um mapa bidimensional que preserve, tanto quanto possível, as **distâncias (dissimilaridades)** entre eles. Essa é a definição do **Escalonamento Multidimensional (MDS)**: a partir de uma matriz de dissimilaridades n × n, busca-se uma configuração de pontos em poucas dimensões cujas distâncias euclidianas reproduzam as originais. Utilizaram-se as cinco variáveis comportamentais (Gasto Online, Gasto Loja, Freq. Online, Freq. Loja e Tempo de Relação). Como estão em escalas muito distintas (R$, contagens, meses), foram **padronizadas (escore z)** antes do cálculo da **distância euclidiana**, para que nenhuma variável domine a distância por causa da unidade de medida. Como as dissimilaridades são métricas (razão), adotou-se o **MDS métrico clássico (Torgerson)**, que obtém as coordenadas pela decomposição espectral da matriz de produtos escalares duplamente centrada; como verificação, ajustou-se também o **MDS não métrico de Kruskal**, que preserva apenas a ordem das distâncias.

5.2 Validação

O MDS não exige normalidade nem outros pressupostos distribucionais; as condições a verificar são (i) a escolha adequada da medida de distância (euclidiana em variáveis padronizadas, justificada acima), (ii) a ausência de autovalores negativos relevantes na solução clássica – todos os autovalores são não negativos, o que confirma a natureza euclidiana das distâncias – e (iii) a qualidade do ajuste, medida pelo stress e pelo RSQ.

5.3 Métricas de ajuste

Tabela 18 – Indicadores de ajuste da solução métrica clássica por número de dimensões

Dimensões	Stress-1 de Kruskal	Classificação (Kruskal)	RSQ	Variância acumulada (autovalores)
1	0,4798	pobre	0,5240	46,8%
2	0,1814	razoável	0,8994	81,5%
3	0,0459	excelente	0,9922	95,9%
4	0,0044	perfeito	0,9999	99,6%
5	0,0000	perfeito	1,0000	100,0%

Na solução bidimensional, o **stress-1** calculado entre as dissimilaridades originais e as distâncias do mapa é **0,181**. A classificação "razoável" usa apenas como referência a escala interpretativa usualmente associada a Kruskal; ela não significa que o algoritmo ajustado tenha sido o MDS não métrico. O **RSQ é 0,899** e as duas dimensões concentram 81,5% da soma dos autovalores. Em análise complementar, o MDS não métrico de Kruskal em 2D obteve stress-1 = 0,127 e RSQ = 0,923. Os resultados dos dois procedimentos devem ser distinguidos: o clássico métrico procura reproduzir as distâncias, enquanto o não métrico preserva principalmente sua ordenação. A curva de stress (Figura 6) mostra melhora expressiva em 3 dimensões (stress 0,046); optou-se pela solução 2D por facilitar a visualização e atender ao objetivo de síntese.

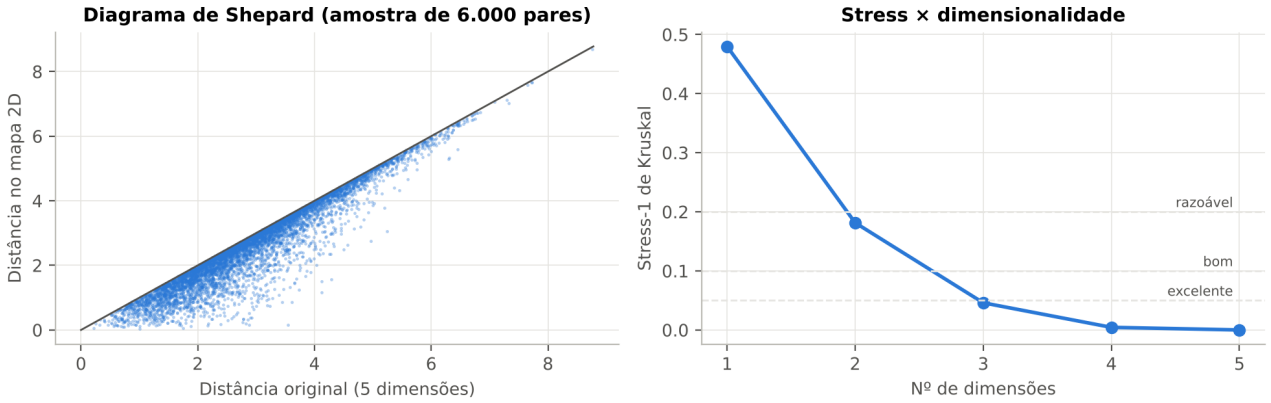


Figura 6 – Qualidade do ajuste: diagrama de Shepard da solução 2D (esq.) e curva de stress (dir.).

5.4 Interpretação da configuração

Tabela 19 – Correlação entre as variáveis originais e as coordenadas do mapa

Variável	Dimensão 1	Dimensão 2
Gasto Online	0,771	0,441
Gasto Loja	0,715	-0,691
Freq. Online	0,720	0,583
Freq. Loja	0,702	-0,701
Tempo de Relação	0,474	0,477

Dimensão 1 (horizontal) – volume geral de relacionamento: todas as variáveis se correlacionam positivamente com ela (0,47 a 0,77). Clientes à direita compram mais, nos dois canais. **Dimensão 2 (vertical) – preferência de canal:** opõe as variáveis online e de tempo de relação (positivas) às de loja física (negativas, ≈ −0,70). Clientes no alto são predominantemente digitais; embaixo, predominantemente de loja física.

Tabela 20 – Posição média dos grupos no mapa

Grupo	Centróide Dim. 1	Centróide Dim. 2
Inativo/Baixo Risco (0)	-0,373	0,085
Ativo/Alto Valor (1)	0,426	-0,098
Norte	-0,421	-0,044
Sul	0,386	0,011
Centro	-0,005	0,031

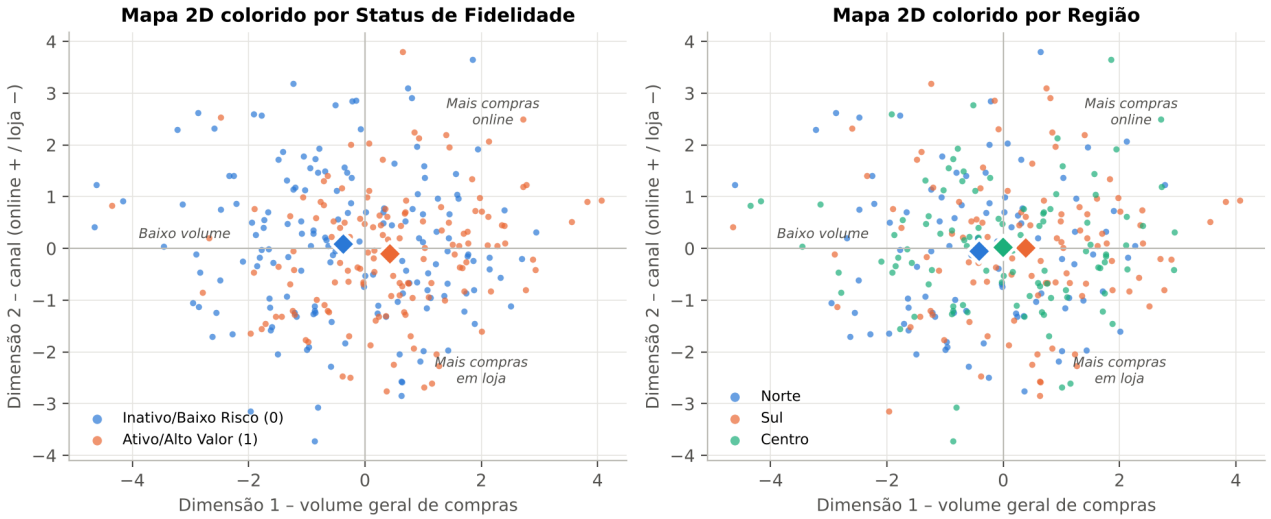


Figura 5 – Configuração bidimensional do MDS (losangos = centróides dos grupos).

Proximidade e agrupamento. No mapa, a distância entre dois pontos é proporcional à dissimilaridade de comportamento: clientes próximos têm perfis de compra parecidos e podem receber a mesma abordagem. A configuração não mostra “ilhas” bem separadas, e sim um **contínuo** com densidade maior no centro, organizado ao longo de dois gradientes (volume e canal). Os quadrantes definem perfis naturais: digitais intensos (direita-alto), lojistas intensos (direita-baixo), digitais leves (esquerda-alto) e clientes de baixo envolvimento (esquerda). Os clientes Ativos/Alto Valor deslocam-se para a direita (centróide 0,43 vs. -0,37) e os do Sul também (maior gasto), mas com grande sobreposição: a distância média entre clientes de grupos de status diferentes (2,57) é quase igual à distância média dentro do mesmo grupo (2,49). Isso é coerente com a Questão 3: o status não é visível no comportamento “bruto” (volume e canal), mas apenas em uma combinação específica (gasto por transação) que a análise discriminante isolou.

5.5 Interpretação negocial

O mapa é uma ferramenta de segmentação visual: (i) a **posição horizontal** indica o potencial de valor e deve orientar a intensidade do investimento de relacionamento; (ii) a **posição vertical** indica o canal preferido e deve orientar onde a comunicação é feita (aplicativo/e-mail para o alto do mapa; encarte, vendedor e eventos em loja para a parte de baixo); (iii) clientes do quadrante esquerdo-baixo são candidatos a campanhas de reativação. Como os perfis formam um contínuo, recomenda-se tratar a segmentação por gradientes (escores) e não por fronteiras rígidas, e reconstruir o mapa periodicamente para acompanhar migrações de clientes entre perfis.

6. Parte IV – Relação entre Engajamento Operacional e Retorno Financeiro/Percepção

6.1 Metodologia

Há dois **conjuntos de variáveis quantitativas**, sem que um seja a única resposta do outro: Bloco 1 (Freq. Online, Freq. Loja, Tempo de Relação) e Bloco 2 (Gasto Online, Gasto Loja, NPS). O interesse é a **relação global entre os blocos**. Regressões múltiplas separadas tratariam cada variável do Bloco 2 isoladamente e ignorariam as correlações dentro de cada bloco. A **Análise de Correlação Canônica** é o método apropriado: ela encontra pares de combinações lineares U_k = **a**'**X** (Bloco 1) e V_k = **b**'**Y** (Bloco 2) com correlação máxima, sendo cada par não correlacionado com os anteriores. As correlações canônicas são as raízes dos autovalores de $\mathbf{R_{11}}^{-1}\mathbf{R_{12}}\mathbf{R_{22}}^{-1}\mathbf{R_{21}}$; com 3 variáveis em cada bloco existem até 3 pares. Utilizou-se a matriz de correlações (variáveis padronizadas), pois as unidades são distintas.

6.2 Validação dos pressupostos

- **Linearidade:** as correlações de Pearson e de Spearman entre os blocos são praticamente iguais (ex.: Freq. Loja × Gasto Loja 0,979 vs. 0,976; Freq. Online × Gasto Online 0,795 vs. 0,764), indicando relações lineares.
- **Normalidade multivariada** (necessária para os testes de significância): Mardia não rejeita a assimetria (χ^2 = 62,63; p = 0,2528); a curtose é levemente inferior à esperada (b_2 = 44,91 vs. 48; p = 0,0064) pelo truncamento do NPS – desvio de pequena magnitude, irrelevante com n = 300.
- **Multicolinearidade dentro dos blocos:** VIFs entre 1,01 e 1,30 (calculados dentro de cada bloco) – sem problema, o que torna os coeficientes canônicos estáveis e interpretáveis.
- **Tamanho amostral:** 300 observações para 6 variáveis (50 por variável), acima do mínimo recomendado (≈ 10 a 20 por variável).

Tabela 21 – Correlações entre os blocos (R_{12})

Bloco 1 \ Bloco 2	Gasto Online	Gasto Loja	NPS
Freq. Online	0,795	0,099	-0,044
Freq. Loja	0,192	0,979	0,168
Tempo de Relação	0,331	0,038	-0,071

6.3 Correlações canônicas e significância

Tabela 22 – Testes sequenciais das correlações canônicas

Dimensões testadas	Corr. canônica	R^2 canônico	Λ de Wilks	χ^2 de Bartlett	gl	p (χ^2)	F de Rao	p (F)
1 a 3	0,9829	0,9660	0,00526	1.550,93	9	< 0,0001	607,63	< 0,0001
2 a 3	0,9191	0,8448	0,15467	551,54	4	< 0,0001	227,55	< 0,0001
3	0,0580	0,0034	0,99664	0,99	1	0,3188	1,00	0,3188

O teste global (todas as dimensões) é altamente significativo: Λ de Wilks = 0,00526, Traço de Pillai = 1,814, Traço de Hotelling-Lawley = 33,88, maior raiz de Roy = 0,9660, todos com p < 0,0001. Pelos testes sequenciais, **as duas primeiras dimensões são significativas** (r_{c1} = 0,983; r_{c2} =

0,919) e a terceira não (r_{c3} = 0,058; p = 0,3188). Interpretam-se, portanto, apenas os dois primeiros pares.

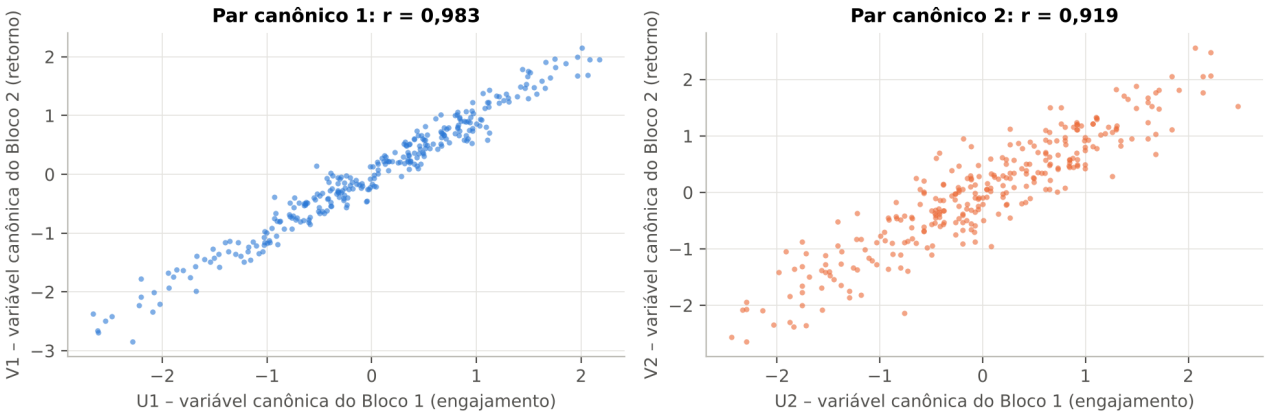


Figura 7 – Escores dos dois pares canônicos significativos.

6.4 Estrutura de pesos e cargas

Tabela 23 – Bloco 1 (Engajamento Operacional): coeficientes padronizados, cargas e cargas cruzadas

Variável	Coef. padr. 1	Coef. padr. 2	Carga 1	Carga 2	Carga cruzada 1	Carga cruzada 2
Freq. Online	-0,213	0,981	-0,118	0,993	-0,116	0,913
Freq. Loja	0,998	0,119	0,976	0,216	0,960	0,198
Tempo de Relação	-0,008	0,000	-0,058	0,445	-0,057	0,409

Tabela 24 – Bloco 2 (Retorno Financeiro e Percepção): coeficientes padronizados, cargas e cargas cruzadas

Variável	Coef. padr. 1	Coef. padr. 2	Carga 1	Carga 2	Carga cruzada 1	Carga cruzada 2
Gasto Online	-0,267	1,107	0,020	0,874	0,019	0,803
Gasto Loja	1,016	0,080	0,972	0,232	0,955	0,213
NPS	0,096	-0,550	0,180	-0,025	0,177	-0,023

Tabela 25 – Variância extraída e índices de redundância

Par	R^2 canônico	Var. extraída Bloco 1	Redundância Bloco 1 | Bloco 2	Var. extraída Bloco 2	Redundância Bloco 2 | Bloco 1
Par 1	0,9660	0,324	0,313	0,326	0,315
Par 2	0,8448	0,410	0,347	0,273	0,230
Par 3	0,0034	0,266	0,001	0,401	0,001
Total		1,000	0,660	1,000	0,547

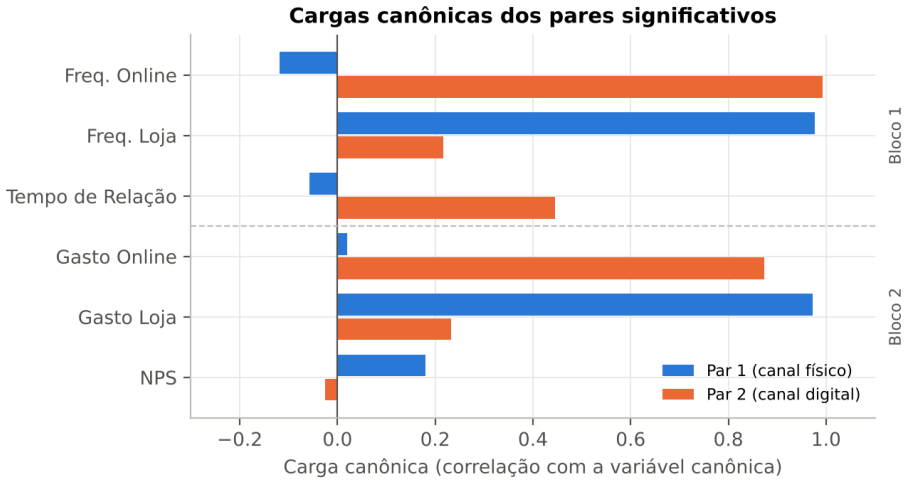


Figura 8 – Estrutura de cargas: o Par 1 é formado pelo canal físico e o Par 2 pelo canal digital.

- **Par 1 – eixo do canal físico (r_c = 0,983):** U_1 é praticamente a própria Freq. Loja (carga 0,976) e V_1 é praticamente o Gasto Loja (carga 0,972). O NPS tem participação pequena e positiva (0,180). A relação é quase determinística: quem vai mais à loja gasta proporcionalmente mais na loja.
- **Par 2 – eixo do canal digital (r_c = 0,919):** U_2 é dominado por Freq. Online (carga 0,993) com contribuição do Tempo de Relação (0,445); V_2 é dominado por Gasto Online (0,874). O NPS recebe **coeficiente negativo** (-0,550) com carga quase nula: ele atua como supressor, removendo do Gasto Online a parte associada à fidelidade/satisfação, que não é explicada pelo engajamento – o que eleva a correlação do par. O Tempo de Relação tem coeficiente padronizado quase nulo: sua carga vem da correlação com Freq. Online (0,45), ou seja, clientes antigos gastam mais online porque compram mais vezes.
- **Redundância:** os dois primeiros pares explicam juntos 54,5% da variância do Bloco 2 a partir do Bloco 1 (e 65,9% no sentido inverso). O restante corresponde sobretudo ao NPS, que fica isolado na terceira dimensão não significativa (carga −0,98 em V_3).

6.5 Relação teórica e interpretação negocial

A relação entre o padrão de uso e o retorno é forte, mas **organizada por canal**: há dois "circuitos" praticamente independentes – frequência em loja → gasto em loja e frequência online (impulsionada pelo tempo de relação) → gasto online. Isso significa que o engajamento em um canal não "transborda" para o retorno do outro canal. Já a **percepção da marca (NPS) não é explicada pelo engajamento operacional**: comprar mais vezes ou estar há mais tempo no programa não torna o cliente mais promotor; o NPS se associa ao gasto online por meio de outros fatores (satisfação, região e status de fidelidade, vistos nas partes anteriores). Implicações: (i) metas de receita podem ser projetadas a partir de metas de frequência por canal – aumentar uma visita física por ano equivale a ≈ R$ 40 em gasto na loja e uma transação digital a ≈ R$ 35 online; (ii) programas de omnicanalidade precisam de incentivos específicos para cruzar canais, pois isso não ocorre espontaneamente; (iii) ações para melhorar o NPS devem atuar na experiência e na satisfação (Parte I), e não apenas em estímulos de frequência; (iv) o tempo de relação gera valor apenas indiretamente, via frequência digital – a retenção deve vir acompanhada de ativação.

7. Síntese para a tomada de decisão

Questão	Método	Principal achado	Ação recomendada
1. Satisfação por região	ANOVA de um fator + Tukey	Norte < Sul < Centro, todas diferentes ($\eta^2 = 0,24$)	Plano de experiência para o Norte; Centro como benchmark; metas regionalizadas
2. Vetor (Gasto Online, Gasto Loja, NPS)	MANOVA	Efeito global significativo ($\Lambda = 0,811$); Sul lidera em gasto, Centro em NPS	Ativação digital no Norte; monetizar a boa percepção do Centro
3. Separação por Status	Análise discriminante linear de Fisher	Gasto Online tem a maior diferença média; há também diferenças menores em Gasto Loja e Freq. Loja. Erro observado: 0,0%	Tratar como indicador inicial; validar em dados externos antes de definir elegibilidade ou risco
4. Mapa perceptual	Escalonamento multidimensional	Dois gradientes: volume e canal (stress 0,181; RSQ 0,899)	Segmentação contínua por valor (eixo 1) e canal (eixo 2)
5. Engajamento × Retorno	Correlação canônica	Dois pares significativos, um por canal (0,98 e 0,92); NPS não explicado pelo engajamento	Metas de receita via frequência por canal; NPS via experiência

Em conjunto, as análises indicam diferenças regionais na satisfação e no conjunto de indicadores financeiros/perceptuais; associação forte entre o status de fidelidade e o perfil de gastos; e relações entre frequência e gasto predominantemente dentro de cada canal. Como há colinearidade entre variáveis de gasto e frequência, a interpretação dos coeficientes discriminantes individuais exige cautela. As recomendações devem ser tratadas como **hipóteses gerenciais a validar em dados reais**, e não como relações causais demonstradas pela simulação.

Nota metodológica: todos os testes foram conduzidos ao nível de significância de 5%. A base é sintética e foi reproduzida de forma independente, com gerador pseudoaleatório diferente do SAS; por isso, os resultados não devem ser apresentados como idênticos aos de uma eventual base SAS original. A separação perfeita observada na análise discriminante é específica desta amostra e não garante desempenho semelhante em clientes reais. Recomenda-se validar o modelo em dados externos antes de qualquer uso operacional.