Curso de Ciência de Dados e Inteligência Artificial
Análise Multivariada

# Modelagem Estatística Multivariada e Avaliação de Performance

Relatório técnico – Comportamento, satisfação e padrão financeiro de clientes de uma rede de varejo

Aluno(a): _____

Novembro de 2026

# Sumário

1. Base de dados e visão geral
2. Parte I – Comparação do Score de Satisfação entre regiões (ANOVA)
3. Parte II – Efeito conjunto da Região sobre Gasto Online, Gasto Loja e NPS (MANOVA)
4. Parte II (Questão 3) – Função discriminante para o Status de Fidelidade
5. Parte III – Mapeamento perceptual dos perfis (Escalonamento Multidimensional)
6. Parte IV – Relação entre Engajamento Operacional e Retorno Financeiro/Percepção (Correlação Canônica)
7. Síntese para a tomada de decisão

Cada seção apresenta: **Metodologia** (justificativa da escolha do método), **Validação** (testes de pressupostos), **Resultados e Tabelas** e **Interpretação Negocial**.

# 1. Base de dados e visão geral

A base contém **300 clientes** e foi gerada exatamente conforme a especificação do enunciado (mesmas distribuições, efeitos de região e de fidelidade, regras de arredondamento e truncamento, semente 12345). Como o gerador pseudoaleatório utilizado não é o do SAS, os valores individuais não coincidem com os do arquivo SAS, mas a estrutura populacional é idêntica, de modo que as conclusões são equivalentes. A distribuição dos clientes é: Norte = 95, Sul = 105, Centro = 100; Status de Fidelidade 0 = 160 (53%) e 1 = 140 (47%). Região e status são independentes (qui-quadrado = 2,72, gl = 2, p = 0,2561), o que evita confusão entre os dois fatores nas análises seguintes. Não há valores ausentes.

**Tabela 1 – Estatísticas descritivas das variáveis contínuas (n = 300)**

| Variável | Média | Desvio-padrão | Mínimo | Mediana | Máximo | Assimetria | Curtose (exc.) |
|---|---|---|---|---|---|---|---|
| Gasto Online | 1.078,52 | 184,39 | 556,85 | 1.095,57 | 1.545,26 | -0,16 | -0,22 |
| Gasto Loja | 574,02 | 122,76 | 231,16 | 578,39 | 816,22 | -0,39 | -0,13 |
| Freq. Online | 16,65 | 4,28 | 6,00 | 17,00 | 28,00 | -0,10 | -0,40 |
| Freq. Loja | 8,08 | 3,04 | 0,00 | 8,00 | 14,00 | -0,39 | -0,13 |
| Score de Satisfação | 7,63 | 1,16 | 4,50 | 7,60 | 10,00 | 0,07 | -0,56 |
| Tempo de Relação | 24,46 | 10,33 | 1,00 | 25,00 | 52,00 | 0,09 | -0,38 |
| NPS | 87,38 | 8,65 | 67,00 | 87,00 | 100,00 | -0,11 | -1,21 |

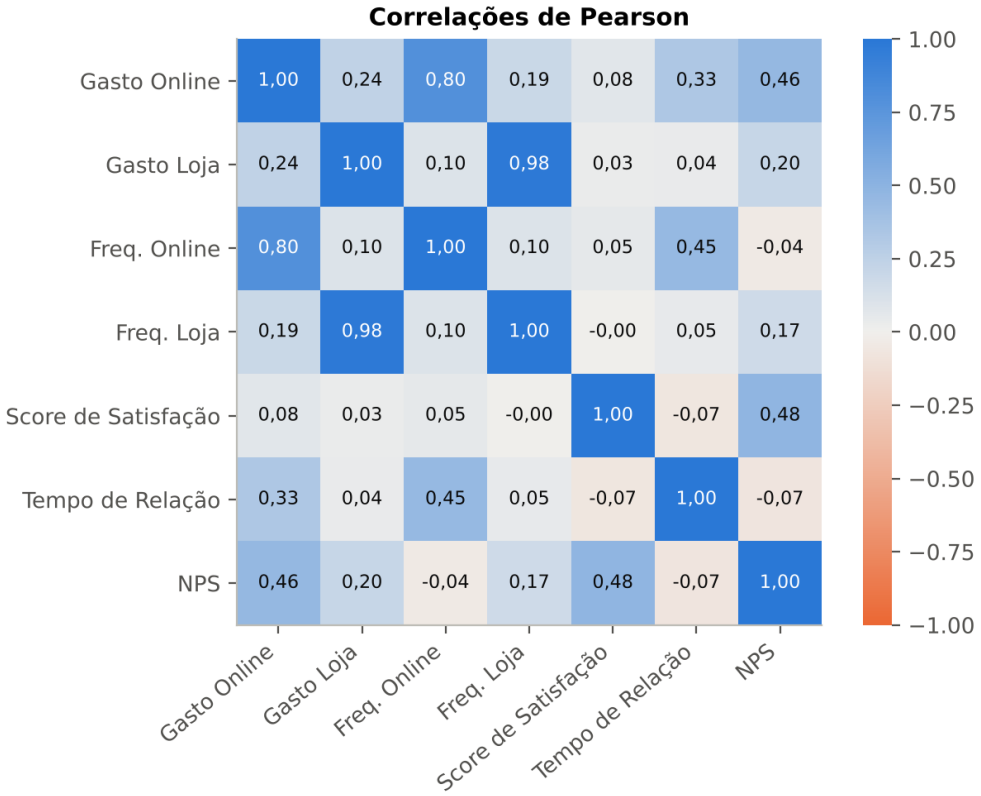



Figura 1 – Matriz de correlações. Destacam-se Freq. Loja × Gasto Loja (0,98), Freq. Online × Gasto Online (0,80) e Gasto Online × NPS (0,46).

# 2. Parte I – Comparação do Score de Satisfação entre regiões

## 2.1 Metodologia

A variável resposta (Score de Satisfação) é **quantitativa contínua** e o fator explicativo (Região) é **categórico com três níveis independentes** (cada cliente pertence a uma única região). O objetivo é testar simultaneamente $H_0$: $\mu_{Norte} = \mu_{Sul} = \mu_{Centro}$. A ferramenta adequada é a **Análise de Variância (ANOVA) de um fator**, que decompõe a variabilidade total em uma parcela atribuída às diferenças entre as médias das regiões e outra atribuída à variação dentro das regiões, comparando-as pela estatística F. Realizar três testes t em pares não é adequado, pois inflaria a taxa de erro tipo I global ($1 - 0{,}95^3 \approx 14\%$). Havendo rejeição de $H_0$, aplica-se um procedimento de **comparações múltiplas post hoc** (Tukey HSD, apropriado para todas as comparações par a par com controle do erro global; Bonferroni como confirmação) para identificar quais regiões diferem.

## 2.2 Validação dos pressupostos

- **Independência das observações:** garantida pelo desenho – cada cliente é observado uma vez e pertence a uma só região.
- **Normalidade:** o teste de Shapiro-Wilk sobre os **resíduos** do modelo (que é o pressuposto formal) não rejeita a normalidade (W = 0,9956; p = 0,5548), resultado confirmado por Kolmogorov-Smirnov (D = 0,0467; p = 0,5150) e pelo Q-Q plot (Figura 2). Por grupo, Norte (p = 0,0494) e Centro (p = 0,0248) apresentam desvios marginais, explicados pelo truncamento da nota em 1 e 10 (efeito teto no Centro). Assimetrias e curtoses estão entre −0,6 e 0,6 e os grupos têm n ≥ 95, de modo que a ANOVA é robusta (Teorema Central do Limite).
- **Homogeneidade das variâncias:** Levene (centrado na média) F = 0,583, p = 0,5588; Brown-Forsythe (mediana) F = 0,592, p = 0,5536; Bartlett $\chi^2$ = 0,555, p = 0,7575. Nenhum rejeita a igualdade das variâncias (desvios-padrão entre 0,99 e 1,06).

**Tabela 2 – Estatísticas descritivas do Score de Satisfação por região**

| Região | n | Média | Desvio-padrão | Mediana | Assimetria | Curtose | Shapiro W | p-valor |
|---|---|---|---|---|---|---|---|---|
| Norte | 95 | 6,956 | 0,987 | 6,90 | 0,54 | 0,02 | 0,9733 | 0,0494 |
| Sul | 105 | 7,541 | 0,994 | 7,50 | -0,23 | 0,16 | 0,9866 | 0,3737 |
| Centro | 100 | 8,369 | 1,057 | 8,30 | -0,30 | -0,54 | 0,9706 | 0,0248 |

## 2.3 Resultados

**Tabela 3 – Quadro da ANOVA de um fator**

| Fonte de variação | gl | Soma de quadrados | Quadrado médio | F | p-valor |
|---|---|---|---|---|---|
| Entre regiões (Regiao) | 2 | 98,627 | 49,314 | 48,023 | < 0,0001 |
| Dentro das regiões (resíduo) | 297 | 304,982 | 1,027 | | |
| Total | 299 | 403,609 | | | |

A estatística F = 48,02 (gl = 2; 297) é altamente significativa (p < 0,0001): rejeita-se $H_0$. O tamanho de efeito é grande: $\eta^2$ = 0,244 e $\omega^2$ = 0,239, isto é, cerca de **24% da variabilidade da satisfação é explicada pela região**. Como verificação de robustez, a ANOVA de Welch (que não exige variâncias iguais) fornece F = 46,73 (gl = 2; 197,1), p < 0,0001, e o teste não paramétrico de Kruskal-Wallis fornece H = 73,30, p < 0,0001 – a conclusão é a mesma por todos os caminhos.

**Tabela 4 – Comparações múltiplas post hoc (QME = 1,0269, gl = 297)**

| Comparação | Diferença de médias | IC 95% (Tukey) | p ajustado Tukey | p ajustado Bonferroni | Difere? |
|---|---|---|---|---|---|
| Sul − Norte | 0,585 | [0,247; 0,923] | 0,0002 | 0,0002 | Sim |
| Centro − Norte | 1,413 | [1,071; 1,755] | < 0,0001 | < 0,0001 | Sim |
| Centro − Sul | 0,828 | [0,494; 1,162] | < 0,0001 | < 0,0001 | Sim |

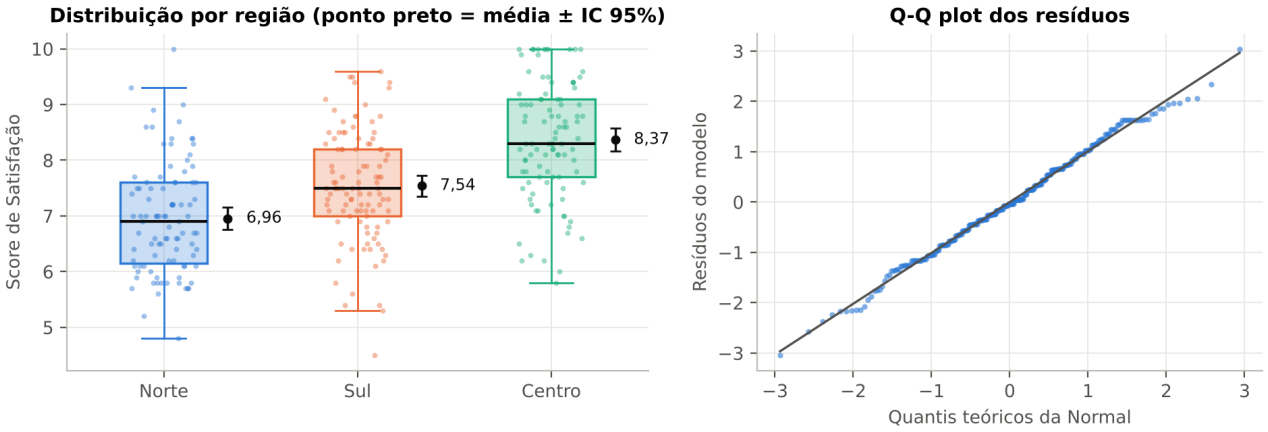



Figura 2 – Score de Satisfação por região e diagnóstico de normalidade dos resíduos da ANOVA.

### 2.4 Interpretação negocial

As três regiões diferem entre si, com ordenação nítida: **Norte (6,96) < Sul (7,54) < Centro (8,37)**. A distância entre o Norte e o Centro é de aproximadamente 1,4 ponto em uma escala de 10 – uma diferença substantiva, não apenas estatística. Recomenda-se: (i) priorizar o Norte em ações de melhoria de experiência (atendimento, prazos de entrega, sortimento), pois é a região com maior espaço de ganho; (ii) estudar as práticas operacionais do Centro como referência interna (benchmark); (iii) no Centro, como parte dos clientes já atinge a nota máxima (efeito teto), a métrica de satisfação perde sensibilidade e deve ser complementada por indicadores como NPS e recompra; (iv) metas de satisfação devem ser regionalizadas, já que uma meta única penalizaria o Norte e seria pouco desafiadora para o Centro.

## 3. Parte II – Efeito conjunto da Região sobre Gasto Online, Gasto Loja e NPS

### 3.1 Metodologia

Agora há **três variáveis dependentes quantitativas medidas no mesmo cliente** e, portanto, correlacionadas (Gasto Online × NPS: r = 0,46; Gasto Online × Gasto Loja: r = 0,24; esfericidade de Bartlett p < 0,0001). O fator continua sendo a Região (3 grupos independentes). O método adequado é a **Análise de Variância Multivariada (MANOVA)**, que testa $H_0$: $\boldsymbol{\mu}_{Norte} = \boldsymbol{\mu}_{Sul} = \boldsymbol{\mu}_{Centro}$, em que cada $\boldsymbol{\mu}$ é o vetor de médias (Gasto Online, Gasto Loja, NPS). A MANOVA compara a matriz de somas de quadrados e produtos cruzados entre grupos (**H**) com a matriz dentro dos grupos (**E**), considerando variâncias e covariâncias simultaneamente, e controla o erro tipo I global em um único teste. Os quatro critérios clássicos são funções dos autovalores de $\mathbf{E}^{-1}\mathbf{H}$ ($\lambda_1$ = 0,1622, $\lambda_2$ = 0,0608).

## 3.2 Validação dos pressupostos

- **Independência:** garantida pelo desenho amostral; **tamanho amostral**: todos os grupos têm n ≥ 95, muito acima do número de variáveis dependentes (3).
- **Normalidade multivariada:** os testes de Mardia por grupo não rejeitam a normalidade (Tabela 6). Nos resíduos combinados, a curtose multivariada é levemente inferior à esperada ($b_2$ = 13,39 vs. 15; p = 0,0109), efeito do truncamento do NPS em 100 (distribuição achatada, platicúrtica), que não compromete o teste dado o tamanho amostral.
- **Homogeneidade das matrizes de covariâncias:** o teste M de Box não rejeita $H_0$ (p = 0,7134); os testes de Levene univariados também não rejeitam.
- **Linearidade e ausência de multicolinearidade entre as VDs:** as correlações são moderadas (máx. 0,46), indicando variáveis relacionadas, mas não redundantes – situação ideal para a MANOVA.

**Tabela 5 – Médias (desvios-padrão) das variáveis dependentes por região**

| Região | Gasto Online (R$) | Gasto Loja (R$) | NPS |
|---|---|---|---|
| Norte | 993,03 (184,22) | 543,40 (125,02) | 83,89 (8,64) |
| Sul | 1.150,72 (167,21) | 605,26 (120,07) | 88,00 (8,57) |
| Centro | 1.083,94 (168,89) | 570,30 (116,53) | 90,05 (7,67) |

**Tabela 6 – Testes de pressupostos da MANOVA**

| Teste de pressuposto | Estatística | p-valor |
|---|---|---|
| Mardia – assimetria (Norte) | 7,78 | 0,6504 |
| Mardia – assimetria (Sul) | 14,43 | 0,1542 |
| Mardia – assimetria (Centro) | 10,98 | 0,3591 |
| Mardia – curtose (Norte) | -1,84 | 0,0655 |
| Mardia – curtose (Sul) | -1,27 | 0,2056 |
| Mardia – curtose (Centro) | -1,23 | 0,2198 |
| M de Box (homog. das matrizes de covariâncias) | 8,88 (gl = 12) | 0,7134 |
| Esfericidade de Bartlett (correlação entre as VDs) | 91,38 (gl = 3) | < 0,0001 |
| Levene – Gasto Online | 1,138 | 0,3219 |
| Levene – Gasto Loja | 0,042 | 0,9592 |
| Levene – NPS | 2,411 | 0,0915 |

## 3.3 Resultados

**Tabela 7 – Testes multivariados para o efeito da Região**

| Critério multivariado | Valor | F aproximado | gl num. | gl den. | p-valor |
|---|---|---|---|---|---|
| Lambda de Wilks | 0,8111 | 10,854 | 6 | 590,0 | < 0,0001 |
| Traço de Pillai | 0,1969 | 10,777 | 6 | 592,0 | < 0,0001 |
| Traço de Hotelling-Lawley | 0,2231 | 10,949 | 6 | 391,6 | < 0,0001 |
| Maior raiz de Roy | 0,1622 | 16,008 | 3 | 296,0 | < 0,0001 |

Todos os critérios rejeitam $H_0$ (p < 0,0001): **o vetor de médias difere entre as regiões**. O Lambda de Wilks de 0,811 indica que cerca de 19% da variância generalizada das três métricas está associada à região ($\eta^2$ multivariado = $1 - \Lambda^{1/s}$ = 0,099 por dimensão). Como o M de Box não

foi significativo, Wilks é o critério de referência; o Traço de Pillai, o mais robusto a violações, confirma o resultado. A maior raiz de Roy, também significativa, indica que a maior parte da diferença se concentra em uma dimensão. As duas funções discriminantes associadas (Tabela 9) mostram que a primeira dimensão (73% da separação) é dominada por **Gasto Online**, e a segunda por **NPS**.

**Tabela 8 – ANOVAs univariadas de acompanhamento**

| Variável dependente | F (2; 297) | p-valor | p Bonferroni (×3) | $\eta^2$ |
|---|---|---|---|---|
| Gasto Online | 20,715 | < 0,0001 | < 0,0001 | 0,122 |
| Gasto Loja | 6,641 | 0,0015 | 0,0045 | 0,043 |
| NPS | 13,831 | < 0,0001 | < 0,0001 | 0,085 |

**Tabela 9 – Coeficientes padronizados das funções discriminantes da MANOVA (escala relativa)**

| Variável | Função 1 | Função 2 |
|---|---|---|
| Gasto Online | 1,000 | -0,464 |
| Gasto Loja | 0,426 | -0,267 |
| NPS | 0,204 | 1,000 |

**Tabela 10 – Pares de regiões significativamente diferentes (Tukey, 5%)**

| Variável | Norte × Sul | Norte × Centro | Sul × Centro |
|---|---|---|---|
| Gasto Online | ✓ | ✓ | ✓ |
| Gasto Loja | ✓ | – | – |
| NPS | ✓ | ✓ | – |

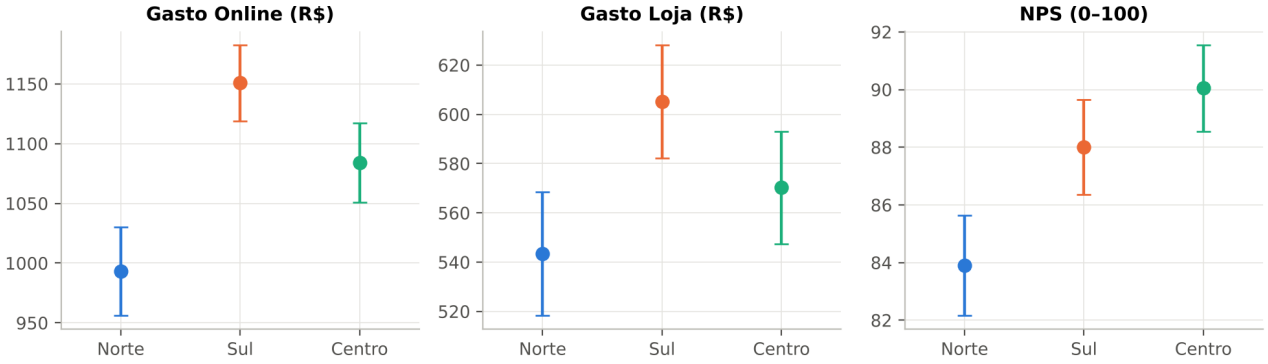



Figura 3 – Médias por região e intervalos de confiança de 95% para as três variáveis dependentes.

## 3.4 Por que a MANOVA pode divergir de três ANOVAs separadas

1. **Controle do erro tipo I:** três ANOVAs a 5% elevam a probabilidade de pelo menos um falso positivo para $1 - 0{,}95^3 \approx 14{,}3\%$. A MANOVA realiza um único teste ao nível nominal de 5%.
2. **Uso da estrutura de covariância:** as ANOVAs tratam cada variável isoladamente e ignoram as correlações. A MANOVA avalia o afastamento entre os centróides dos grupos em uma métrica que leva em conta as covariâncias (distância de Mahalanobis). Duas variáveis correlacionadas carregam informação parcialmente redundante; a MANOVA não a "conta duas vezes", o que pode reduzir a evidência em relação às análises isoladas.
3. **Efeitos de combinação:** grupos podem não diferir de forma relevante em nenhuma variável isolada e, ainda assim, diferir em uma combinação linear delas (por exemplo, quando a relação entre gasto e NPS muda de sentido entre regiões). Nesses casos a MANOVA detecta diferenças invisíveis às ANOVAs. O inverso também ocorre: uma diferença univariada fraca pode não ser

significativa no teste multivariado, que “dilui” o efeito entre os graus de liberdade das três variáveis.

4. **Nesta base**, ambos os enfoques concordam (todas as ANOVAs significativas mesmo após Bonferroni), mas a MANOVA acrescenta que as diferenças regionais **não** são três fenômenos independentes: elas se organizam em duas dimensões (gasto digital e percepção/NPS), e o padrão de pares difere por variável (Tabela 10) – Sul lidera em gasto, Centro em NPS.

### 3.5 Interpretação negocial

A região afeta o “pacote” de desempenho do cliente, mas de forma diferente para cada componente. O **Sul** é a região de maior valor financeiro (Gasto Online médio de R$ 1.151, cerca de R$ 158 acima do Norte), o **Centro** combina gasto intermediário com o maior NPS (90,0), e o **Norte** é inferior em todas as métricas. O gasto em loja física varia pouco entre regiões ($\eta^2 = 0{,}043$; só Norte × Sul difere), logo as diferenças regionais são essencialmente de **canal digital** e de **percepção da marca**. Implicações: investir em ativação digital no Norte; no Centro, converter a boa percepção em gasto (programas de indicação, ofertas personalizadas); no Sul, proteger a base de alto valor e monitorar se o NPS acompanha o gasto. Avaliar só a satisfação (Parte I) levaria a concluir que o Centro é a melhor região; a visão multivariada mostra que, em valor financeiro, o Sul é superior.

## 4. Parte II (Questão 3) – Função discriminante para o Status de Fidelidade

### 4.1 Metodologia

O problema tem uma **variável dependente categórica com dois grupos conhecidos a priori** (Status 0 e 1) e **cinco preditoras quantitativas contínuas**. Deseja-se (a) encontrar a combinação linear das preditoras que maximiza a separação entre os grupos e (b) classificar novos clientes. Essa é exatamente a proposta da **Análise Discriminante Linear de Fisher**: a função $Z = a_1X_1 + \ldots + a_5X_5$ é escolhida de modo a maximizar a razão entre a variabilidade entre grupos e a variabilidade dentro dos grupos, o que, para dois grupos, leva a $\mathbf{a} = \mathbf{S}_p^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_0)$, em que $\mathbf{S}_p$ é a matriz de covariâncias combinada. A forma linear é justificada quando as matrizes de covariâncias dos grupos são iguais (caso contrário, seria indicada a forma quadrática). A classificação usa o ponto de corte entre os centróides dos grupos, com probabilidades a priori iguais e, como sensibilidade, proporcionais aos tamanhos dos grupos.

### 4.2 Validação dos pressupostos

- **Normalidade multivariada em cada grupo:** Mardia não rejeita (Tabela 12).
- **Igualdade das matrizes de covariâncias:** M de Box $\chi^2 = 23{,}10$, gl = 15, p = 0,0820 – não se rejeita a homogeneidade ao nível de 5%, justificando a função **linear**.
- **Multicolinearidade:** há colinearidade forte entre Gasto Loja e Freq. Loja ($r = 0{,}98$; VIF ≈ 28) e moderada entre Gasto Online e Freq. Online ($r = 0{,}80$; VIF ≈ 3,4). Isso não prejudica a capacidade de classificação, mas torna os coeficientes padronizados instáveis e de sinais opostos; por isso a interpretação combina coeficientes e cargas estruturais.
- **Tamanho amostral:** 160 e 140 clientes, isto é, mais de 28 observações por preditora no menor grupo (mínimo usual: 20).

**Tabela 11 – Testes univariados de igualdade de médias entre os grupos**

| Variável | Média Status 0 | Média Status 1 | Λ de Wilks | F (1; 298) | p-valor |
|---|---|---|---|---|---|
| Gasto Online | 991,03 | 1.178,51 | 0,7418 | 103,71 | < 0,0001 |
| Gasto Loja | 549,61 | 601,91 | 0,9547 | 14,15 | 0,0002 |
| Freq. Online | 16,91 | 16,36 | 0,9958 | 1,26 | 0,2630 |
| Freq. Loja | 7,53 | 8,71 | 0,9623 | 11,69 | 0,0007 |
| Tempo de Relação | 24,93 | 23,92 | 0,9976 | 0,71 | 0,3994 |

**Tabela 12 – Pressupostos da análise discriminante**

| Teste de pressuposto | Estatística | p-valor |
|---|---|---|
| Mardia – assimetria (Status 0) | 22,11 | 0,9557 |
| Mardia – assimetria (Status 1) | 23,66 | 0,9271 |
| Mardia – curtose (Status 0) | -1,43 | 0,1514 |
| Mardia – curtose (Status 1) | -1,07 | 0,2842 |
| M de Box | 23,10 (gl = 15) | 0,0820 |

**Tabela 13 – Fatores de inflação da variância**

| Variável | VIF |
|---|---|
| Gasto Online | 3,37 |
| Gasto Loja | 28,65 |
| Freq. Online | 3,37 |
| Freq. Loja | 27,61 |
| Tempo de Relação | 1,25 |

## 4.3 A função discriminante

A função é altamente significativa: Λ de Wilks = 0,0671, $\chi^2$ = 798,5 (gl = 5), p < 0,0001; autovalor = 13,913; **correlação canônica = 0,9659** (93% da variância do escore é explicada pela pertença ao grupo). A distância de Mahalanobis entre os centróides é $D^2$ = 55,53 ($T^2$ de Hotelling: F = 818,1; gl = 5; 294). Centróides: Status 0 = 2,360; Status 1 = 9,812 (escala com variância intra-grupo unitária).

**Tabela 14 – Coeficientes e cargas da função discriminante**

| Variável | Coef. não padronizado | Coef. padronizado | Carga estrutural (intra-grupos) | Correlação com o escore (amostra total) |
|---|---|---|---|---|
| Gasto Online | 0,03719 | 5,916 | 0,158 | 0,526 |
| Gasto Loja | -0,04778 | -5,741 | 0,058 | 0,220 |
| Freq. Online | -1,33798 | -5,726 | -0,017 | -0,067 |
| Freq. Loja | 1,89434 | 5,664 | 0,053 | 0,201 |
| Tempo de Relação | 0,00527 | 0,055 | -0,013 | -0,051 |
| Constante | -5,8376 | | | |

**Pesos padronizados.** Os maiores pesos padronizados (em valor absoluto) são de **Gasto Online (+5,92)**, **Gasto Loja (-5,74)**, **Freq. Online (-5,73)** e **Freq. Loja (+5,66)**; Tempo de Relação tem peso praticamente nulo (0,055). Os sinais opostos dentro de cada par gasto/frequência, consequência da colinearidade, revelam o que a função realmente mede: a razão entre os

coeficientes brutos de Gasto Online e Freq. Online é ≈ −1/36, e a de Gasto Loja e Freq. Loja ≈ −1/40. Ou seja, o eixo discriminante é essencialmente **“gasto além do que a frequência explicaria”** (≈ Gasto Online − 36 × Freq. Online), uma medida de **ticket médio**, corrigida pelo componente regional capturado pelo gasto em loja (que expurga parte do efeito da região sobre o gasto). A correlação desse índice simples (Gasto Online − 35 × Freq. Online) com o escore discriminante é 0,957. Pelas cargas estruturais e pelas correlações na amostra total, **Gasto Online é a variável mais associada ao eixo**, seguida de Gasto Loja e Freq. Loja; Freq. Online e Tempo de Relação são irrelevantes isoladamente (testes univariados não significativos), mas Freq. Online é indispensável como variável “supressora”.

## 4.4 Capacidade de classificação

**Tabela 15 – Matriz de confusão por resubstituição (a priori iguais)**

| Grupo real | Previsto 0 | Previsto 1 | Total | % correto |
|---|---|---|---|---|
| Inativo/Baixo Risco (0) | 160 | 0 | 160 | 100,0% |
| Ativo/Alto Valor (1) | 0 | 140 | 140 | 100,0% |

**Tabela 16 – Matriz de confusão por validação cruzada “deixe-um-fora” (Lachenbruch)**

| Grupo real | Previsto 0 | Previsto 1 | Total | % correto |
|---|---|---|---|---|
| Inativo/Baixo Risco (0) | 160 | 0 | 160 | 100,0% |
| Ativo/Alto Valor (1) | 0 | 140 | 140 | 100,0% |

**Tabela 17 – Validação com amostra de teste (função estimada em 210 clientes, aplicada a 90 novos)**

| Grupo real | Previsto 0 | Previsto 1 | Total | % correto |
|---|---|---|---|---|
| Inativo/Baixo Risco (0) | 48 | 0 | 48 | 100,0% |
| Ativo/Alto Valor (1) | 0 | 42 | 42 | 100,0% |

A taxa de erro aparente (APER) é de 0,0%, a taxa de erro estimada por validação cruzada é de 0,0% e, na amostra de teste, 0,0%. Com probabilidades a priori proporcionais ($\pi_1$ = 0,467) o resultado é idêntico (erro de 0,0%). O desempenho supera com folga os critérios de referência: chance proporcional $C_{pro}$ = 50,2% e chance máxima $C_{max}$ = 53,3% (a regra de 25% acima da chance exigiria ≥ 62,8%); o Q de Press = 300,0 é muito superior ao valor crítico $\chi^2_{1;\,0,01}$ = 6,63. A separação perfeita é coerente com a forma como a base foi construída (o status adiciona R$ 200 ao gasto online, com ruído de desvio-padrão R$ 15) e deve ser vista como um limite superior: em dados reais, com mais ruído, espera-se algum erro, e o modelo deve ser revalidado periodicamente.

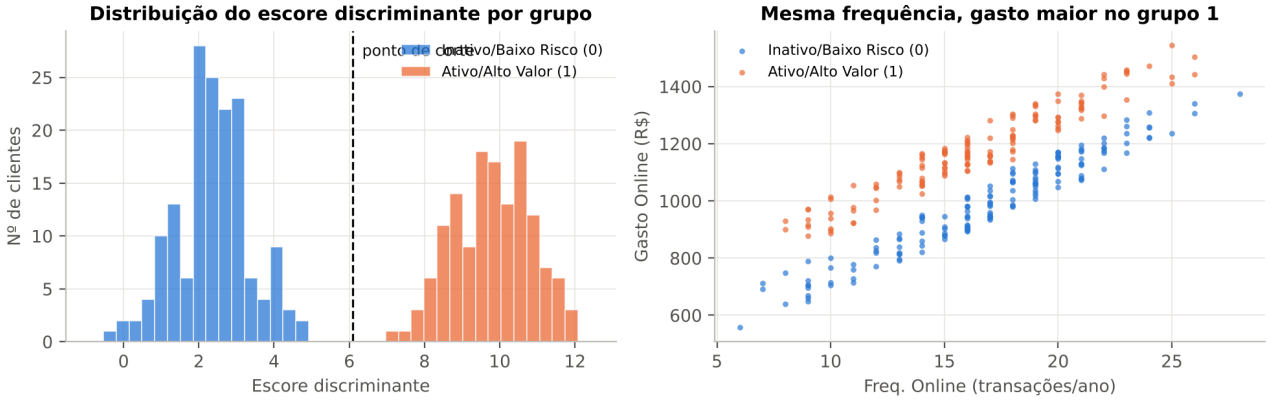



Figura 4 – Separação obtida pela função discriminante (esq.) e a origem da separação: para cada nível de frequência online, os clientes Ativos/Alto Valor gastam sistematicamente mais (dir.).

### 4.5 Interpretação negocial

O que distingue o cliente Ativo/Alto Valor **não é comprar mais vezes nem estar há mais tempo no programa** – a frequência online e o tempo de relação são estatisticamente iguais nos dois grupos –, mas **gastar mais em cada compra online** (cerca de R$ 190 a mais por ano para a mesma frequência). Implicações: (i) o critério operacional de elegibilidade e o monitoramento de risco devem se basear no **ticket médio digital**, não na contagem de transações; (ii) campanhas para migrar clientes do grupo 0 para o grupo 1 devem focar em aumento de cesta (cross-sell, up-sell, frete grátis acima de um valor) e não em frequência; (iii) a função pode ser aplicada a novos clientes como regra de pontuação simples (escore acima do ponto de corte ⇒ perfil de alto valor), com erro estimado praticamente nulo nesta base.

## 5. Parte III – Mapeamento perceptual dos perfis (Escalonamento Multidimensional)

### 5.1 Metodologia

O objetivo é representar os 300 clientes em um mapa bidimensional que preserve, tanto quanto possível, as **distâncias (dissimilaridades)** entre eles. Essa é a definição do **Escalonamento Multidimensional (MDS)**: a partir de uma matriz de dissimilaridades n × n, busca-se uma configuração de pontos em poucas dimensões cujas distâncias euclidianas reproduzam as originais. Utilizaram-se as cinco variáveis comportamentais (Gasto Online, Gasto Loja, Freq. Online, Freq. Loja e Tempo de Relação). Como estão em escalas muito distintas (R$, contagens, meses), foram **padronizadas (escore z)** antes do cálculo da **distância euclidiana**, para que nenhuma variável domine a distância por causa da unidade de medida. Como as dissimilaridades são métricas (razão), adotou-se o **MDS métrico clássico (Torgerson)**, que obtém as coordenadas pela decomposição espectral da matriz de produtos escalares duplamente centrada; como verificação, ajustou-se também o **MDS não métrico de Kruskal**, que preserva apenas a ordem das distâncias.

### 5.2 Validação

O MDS não exige normalidade nem outros pressupostos distribucionais; as condições a verificar são (i) a escolha adequada da medida de distância (euclidiana em variáveis padronizadas, justificada acima), (ii) a ausência de autovalores negativos relevantes na solução clássica – todos os autovalores são não negativos, o que confirma a natureza euclidiana das distâncias – e (iii) a qualidade do ajuste, medida pelo stress e pelo RSQ.

## 5.3 Métricas de ajuste

**Tabela 18 – Ajuste do MDS métrico por número de dimensões**

| Dimensões | Stress-1 de Kruskal | Classificação (Kruskal) | RSQ | Variância acumulada (autovalores) |
|---|---|---|---|---|
| 1 | 0,4798 | pobre | 0,5240 | 46,8% |
| 2 | 0,1814 | razoável | 0,8994 | 81,5% |
| 3 | 0,0459 | excelente | 0,9922 | 95,9% |
| 4 | 0,0044 | perfeito | 0,9999 | 99,6% |
| 5 | 0,0000 | perfeito | 1,0000 | 100,0% |

Na solução bidimensional, o **stress-1 é 0,181** (ajuste “razoável” pela escala de Kruskal), o **RSQ é 0,899** (90% da variância das distâncias originais é reproduzida pelas distâncias no mapa) e as duas dimensões concentram 81,5% da soma dos autovalores. O MDS não métrico em 2D obteve stress-1 = 0,127 e RSQ = 0,923, ligeiramente melhor por exigir apenas a preservação da ordem das distâncias, e produziu essencialmente a mesma configuração. A curva de stress (Figura 6) mostra um “cotovelo” em 3 dimensões (stress 0,046, excelente); a terceira dimensão corresponde basicamente ao Tempo de Relação. Optou-se pela solução 2D por exigência de visualização e porque o diagrama de Shepard mostra que as distâncias grandes – as que definem a estrutura global e os agrupamentos – são bem preservadas; as distorções concentram-se em pares próximos que o mapa “aproxima” um pouco além do real.

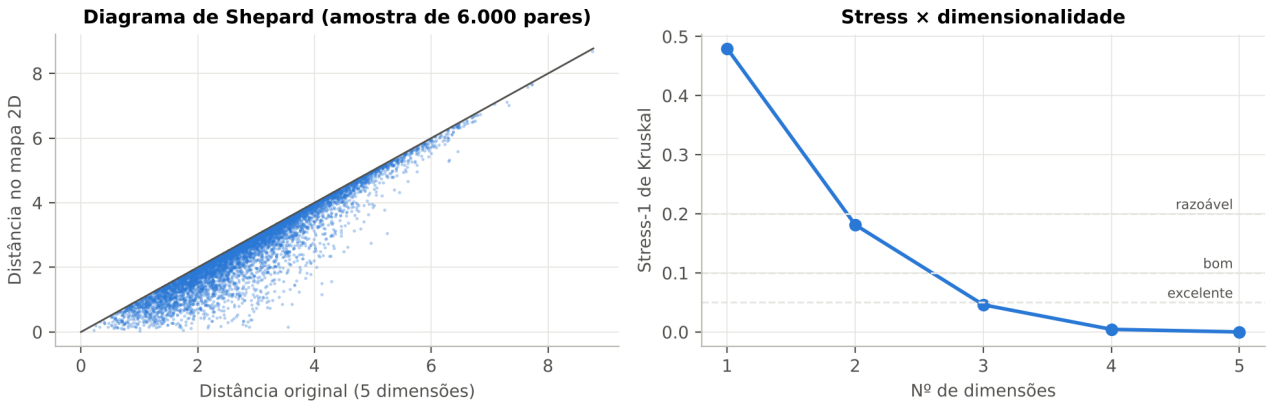



Figura 6 – Qualidade do ajuste: diagrama de Shepard da solução 2D (esq.) e curva de stress (dir.).

## 5.4 Interpretação da configuração

**Tabela 19 – Correlação entre as variáveis originais e as coordenadas do mapa**

| Variável | Dimensão 1 | Dimensão 2 |
|---|---|---|
| Gasto Online | 0,771 | 0,441 |
| Gasto Loja | 0,715 | -0,691 |
| Freq. Online | 0,720 | 0,583 |
| Freq. Loja | 0,702 | -0,701 |
| Tempo de Relação | 0,474 | 0,477 |

**Dimensão 1 (horizontal) – volume geral de relacionamento:** todas as variáveis se correlacionam positivamente com ela (0,47 a 0,77). Clientes à direita compram mais, nos dois canais. **Dimensão 2 (vertical) – preferência de canal:** opõe as variáveis online e de tempo de relação (positivas) às de loja física (negativas, ≈ −0,70). Clientes no alto são predominantemente digitais; embaixo, predominantemente de loja física.

**Tabela 20 – Posição média dos grupos no mapa**

| Grupo | Centróide Dim. 1 | Centróide Dim. 2 |
|---|---|---|
| Inativo/Baixo Risco (0) | -0,373 | 0,085 |
| Ativo/Alto Valor (1) | 0,426 | -0,098 |
| Norte | -0,421 | -0,044 |
| Sul | 0,386 | 0,011 |
| Centro | -0,005 | 0,031 |

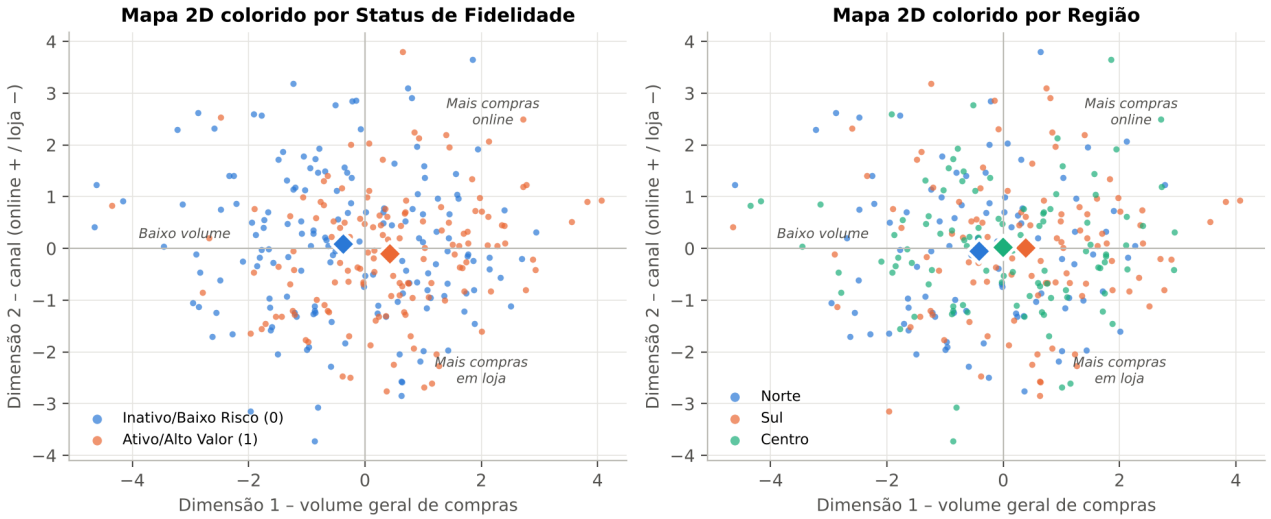



Figura 5 – Configuração bidimensional do MDS (losangos = centróides dos grupos).

**Proximidade e agrupamento.** No mapa, a distância entre dois pontos é proporcional à dissimilaridade de comportamento: clientes próximos têm perfis de compra parecidos e podem receber a mesma abordagem. A configuração não mostra “ilhas” bem separadas, e sim um **contínuo** com densidade maior no centro, organizado ao longo de dois gradientes (volume e canal). Os quadrantes definem perfis naturais: digitais intensos (direita-alto), lojistas intensos (direita-baixo), digitais leves (esquerda-alto) e clientes de baixo envolvimento (esquerda). Os clientes Ativos/Alto Valor deslocam-se para a direita (centróide 0,43 vs. -0,37) e os do Sul também (maior gasto), mas com grande sobreposição: a distância média entre clientes de grupos de status diferentes (2,57) é quase igual à distância média dentro do mesmo grupo (2,49). Isso é coerente com a Questão 3: o status não é visível no comportamento “bruto” (volume e canal), mas apenas em uma combinação específica (gasto por transação) que a análise discriminante isolou.

## 5.5 Interpretação negocial

O mapa é uma ferramenta de segmentação visual: (i) a **posição horizontal** indica o potencial de valor e deve orientar a intensidade do investimento de relacionamento; (ii) a **posição vertical** indica o canal preferido e deve orientar onde a comunicação é feita (aplicativo/e-mail para o alto do mapa; encarte, vendedor e eventos em loja para a parte de baixo); (iii) clientes do quadrante esquerdo-baixo são candidatos a campanhas de reativação. Como os perfis formam um contínuo, recomenda-se tratar a segmentação por gradientes (escores) e não por fronteiras rígidas, e reconstruir o mapa periodicamente para acompanhar migrações de clientes entre perfis.

# 6. Parte IV – Relação entre Engajamento Operacional e Retorno Financeiro/Percepção

## 6.1 Metodologia

Há dois **conjuntos de variáveis quantitativas**, sem que um seja a única resposta do outro: Bloco 1 (Freq. Online, Freq. Loja, Tempo de Relação) e Bloco 2 (Gasto Online, Gasto Loja, NPS). O interesse é a **relação global entre os blocos**. Regressões múltiplas separadas tratariam cada variável do Bloco 2 isoladamente e ignorariam as correlações dentro de cada bloco. A **Análise de Correlação Canônica** é o método apropriado: ela encontra pares de combinações lineares $U_k$ = **a**'**X** (Bloco 1) e $V_k$ = **b**'**Y** (Bloco 2) com correlação máxima, sendo cada par não correlacionado com os anteriores. As correlações canônicas são as raízes dos autovalores de $\mathbf{R_{11}}^{-1}\mathbf{R_{12}}\mathbf{R_{22}}^{-1}\mathbf{R_{21}}$; com 3 variáveis em cada bloco existem até 3 pares. Utilizou-se a matriz de correlações (variáveis padronizadas), pois as unidades são distintas.

## 6.2 Validação dos pressupostos

- **Linearidade:** as correlações de Pearson e de Spearman entre os blocos são praticamente iguais (ex.: Freq. Loja × Gasto Loja 0,979 vs. 0,976; Freq. Online × Gasto Online 0,795 vs. 0,764), indicando relações lineares.
- **Normalidade multivariada** (necessária para os testes de significância): Mardia não rejeita a assimetria ($\chi^2$ = 62,63; p = 0,2528); a curtose é levemente inferior à esperada ($b_2$ = 44,91 vs. 48; p = 0,0064) pelo truncamento do NPS – desvio de pequena magnitude, irrelevante com n = 300.
- **Multicolinearidade dentro dos blocos:** VIFs entre 1,01 e 1,30 (calculados dentro de cada bloco) – sem problema, o que torna os coeficientes canônicos estáveis e interpretáveis.
- **Tamanho amostral:** 300 observações para 6 variáveis (50 por variável), acima do mínimo recomendado (≈ 10 a 20 por variável).

**Tabela 21 – Correlações entre os blocos ($R_{12}$)**

| Bloco 1 \ Bloco 2 | Gasto Online | Gasto Loja | NPS |
|---|---|---|---|
| Freq. Online | 0,795 | 0,099 | -0,044 |
| Freq. Loja | 0,192 | 0,979 | 0,168 |
| Tempo de Relação | 0,331 | 0,038 | -0,071 |

## 6.3 Correlações canônicas e significância

**Tabela 22 – Testes sequenciais das correlações canônicas**

| Dimensões testadas | Corr. canônica | $R^2$ canônico | Λ de Wilks | $\chi^2$ de Bartlett | gl | p ($\chi^2$) | F de Rao | p (F) |
|---|---|---|---|---|---|---|---|---|
| 1 a 3 | 0,9829 | 0,9660 | 0,00526 | 1.550,93 | 9 | < 0,0001 | 607,63 | < 0,0001 |
| 2 a 3 | 0,9191 | 0,8448 | 0,15467 | 551,54 | 4 | < 0,0001 | 227,55 | < 0,0001 |
| 3 | 0,0580 | 0,0034 | 0,99664 | 0,99 | 1 | 0,3188 | 1,00 | 0,3188 |

O teste global (todas as dimensões) é altamente significativo: Λ de Wilks = 0,00526, Traço de Pillai = 1,814, Traço de Hotelling-Lawley = 33,88, maior raiz de Roy = 0,9660, todos com p < 0,0001. Pelos testes sequenciais, **as duas primeiras dimensões são significativas** ($r_{c1}$ = 0,983; $r_{c2}$ =

0,919) e a terceira não ($r_{c3}$ = 0,058; p = 0,3188). Interpretam-se, portanto, apenas os dois primeiros pares.

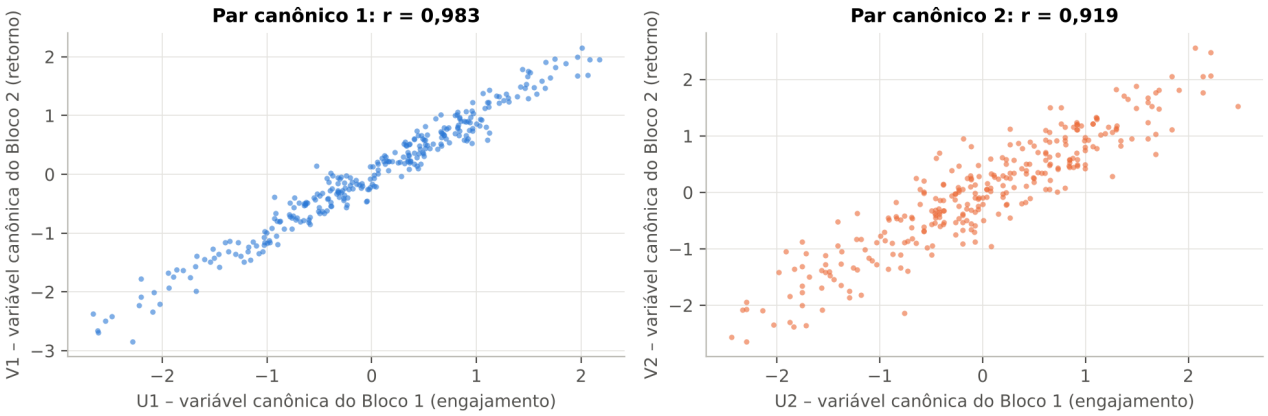



Figura 7 – Escores dos dois pares canônicos significativos.

## 6.4 Estrutura de pesos e cargas

**Tabela 23 – Bloco 1 (Engajamento Operacional): coeficientes padronizados, cargas e cargas cruzadas**

| Variável | Coef. padr. 1 | Coef. padr. 2 | Carga 1 | Carga 2 | Carga cruzada 1 | Carga cruzada 2 |
|---|---|---|---|---|---|---|
| Freq. Online | -0,213 | 0,981 | -0,118 | 0,993 | -0,116 | 0,913 |
| Freq. Loja | 0,998 | 0,119 | 0,976 | 0,216 | 0,960 | 0,198 |
| Tempo de Relação | -0,008 | 0,000 | -0,058 | 0,445 | -0,057 | 0,409 |

**Tabela 24 – Bloco 2 (Retorno Financeiro e Percepção): coeficientes padronizados, cargas e cargas cruzadas**

| Variável | Coef. padr. 1 | Coef. padr. 2 | Carga 1 | Carga 2 | Carga cruzada 1 | Carga cruzada 2 |
|---|---|---|---|---|---|---|
| Gasto Online | -0,267 | 1,107 | 0,020 | 0,874 | 0,019 | 0,803 |
| Gasto Loja | 1,016 | 0,080 | 0,972 | 0,232 | 0,955 | 0,213 |
| NPS | 0,096 | -0,550 | 0,180 | -0,025 | 0,177 | -0,023 |

**Tabela 25 – Variância extraída e índices de redundância**

| Par | $R^2$ canônico | Var. extraída Bloco 1 | Redundância Bloco 1 \| Bloco 2 | Var. extraída Bloco 2 | Redundância Bloco 2 \| Bloco 1 |
|---|---|---|---|---|---|
| Par 1 | 0,9660 | 0,324 | 0,313 | 0,326 | 0,315 |
| Par 2 | 0,8448 | 0,410 | 0,347 | 0,273 | 0,230 |
| Par 3 | 0,0034 | 0,266 | 0,001 | 0,401 | 0,001 |
| Total | | 1,000 | 0,660 | 1,000 | 0,547 |

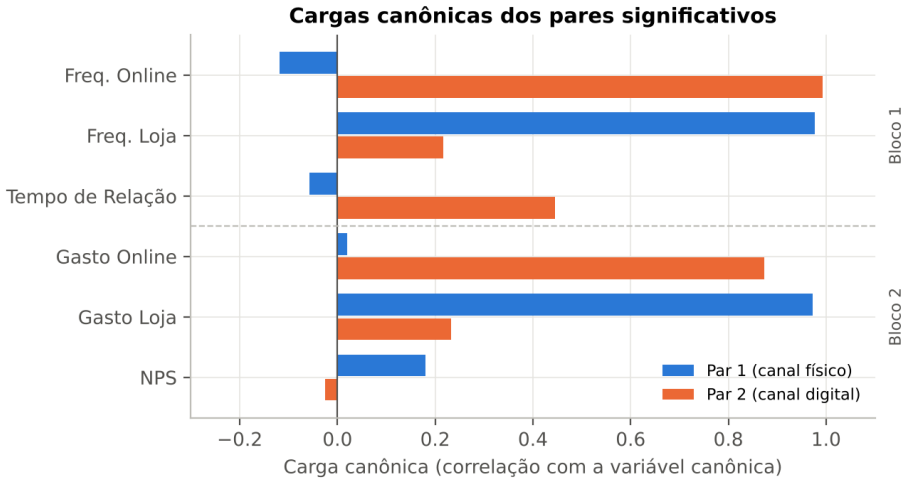



Figura 8 – Estrutura de cargas: o Par 1 é formado pelo canal físico e o Par 2 pelo canal digital.

- **Par 1 – eixo do canal físico ($r_c$ = 0,983):** $U_1$ é praticamente a própria Freq. Loja (carga 0,976) e $V_1$ é praticamente o Gasto Loja (carga 0,972). O NPS tem participação pequena e positiva (0,180). A relação é quase determinística: quem vai mais à loja gasta proporcionalmente mais na loja.
- **Par 2 – eixo do canal digital ($r_c$ = 0,919):** $U_2$ é dominado por Freq. Online (carga 0,993) com contribuição do Tempo de Relação (0,445); $V_2$ é dominado por Gasto Online (0,874). O NPS recebe **coeficiente negativo** (-0,550) com carga quase nula: ele atua como supressor, removendo do Gasto Online a parte associada à fidelidade/satisfação, que não é explicada pelo engajamento – o que eleva a correlação do par. O Tempo de Relação tem coeficiente padronizado quase nulo: sua carga vem da correlação com Freq. Online (0,45), ou seja, clientes antigos gastam mais online porque compram mais vezes.
- **Redundância:** os dois primeiros pares explicam juntos 54,5% da variância do Bloco 2 a partir do Bloco 1 (e 65,9% no sentido inverso). O restante corresponde sobretudo ao NPS, que fica isolado na terceira dimensão não significativa (carga −0,98 em $V_3$).

## 6.5 Relação teórica e interpretação negocial

A relação entre o padrão de uso e o retorno é forte, mas **organizada por canal**: há dois "circuitos" praticamente independentes – frequência em loja → gasto em loja e frequência online (impulsionada pelo tempo de relação) → gasto online. Isso significa que o engajamento em um canal não "transborda" para o retorno do outro canal. Já a **percepção da marca (NPS) não é explicada pelo engajamento operacional**: comprar mais vezes ou estar há mais tempo no programa não torna o cliente mais promotor; o NPS se associa ao gasto online por meio de outros fatores (satisfação, região e status de fidelidade, vistos nas partes anteriores). Implicações: (i) metas de receita podem ser projetadas a partir de metas de frequência por canal – aumentar uma visita física por ano equivale a ≈ R$ 40 em gasto na loja e uma transação digital a ≈ R$ 35 online; (ii) programas de omnicanalidade precisam de incentivos específicos para cruzar canais, pois isso não ocorre espontaneamente; (iii) ações para melhorar o NPS devem atuar na experiência e na satisfação (Parte I), e não apenas em estímulos de frequência; (iv) o tempo de relação gera valor apenas indiretamente, via frequência digital – a retenção deve vir acompanhada de ativação.

## 7. Síntese para a tomada de decisão

| Questão | Método | Principal achado | Ação recomendada |
|---|---|---|---|
| 1. Satisfação por região | ANOVA de um fator + Tukey | Norte < Sul < Centro, todas diferentes ($\eta^2 = 0{,}24$) | Plano de experiência para o Norte; Centro como benchmark; metas regionalizadas |
| 2. Vetor (Gasto Online, Gasto Loja, NPS) | MANOVA | Efeito global significativo ($\Lambda = 0{,}811$); Sul lidera em gasto, Centro em NPS | Ativação digital no Norte; monetizar a boa percepção do Centro |
| 3. Separação por Status | Análise discriminante linear de Fisher | Ticket médio online separa os grupos ($r_c = 0{,}966$); erro de validação 0,0% | Elegibilidade e risco pelo gasto por transação; campanhas de aumento de cesta |
| 4. Mapa perceptual | Escalonamento multidimensional | Dois gradientes: volume e canal (stress 0,181; RSQ 0,899) | Segmentação contínua por valor (eixo 1) e canal (eixo 2) |
| 5. Engajamento × Retorno | Correlação canônica | Dois pares significativos, um por canal (0,98 e 0,92); NPS não explicado pelo engajamento | Metas de receita via frequência por canal; NPS via experiência |

Em conjunto, as análises mostram que a **região** afeta sobretudo a percepção e o gasto digital, que o **status de fidelidade** se manifesta no valor por transação e não na frequência, e que o **engajamento** gera retorno financeiro dentro de cada canal, mas não melhora a percepção da marca. As estratégias de marketing e operação devem, portanto, ser segmentadas simultaneamente por região, canal e valor do cliente.

Nota metodológica: todos os testes foram conduzidos ao nível de significância de 5%. As análises foram realizadas sobre a base sintética gerada segundo a especificação do enunciado; como os dados são simulados, a separação perfeita na análise discriminante e as correlações canônicas muito elevadas refletem a baixa variância dos ruídos definidos na geração.